2023년 AI바우처 지원사업
AI 솔루션 테스트 실무 가이드

2023. 8.

정보통신산업진흥원
National IT Industry Promotion Agency

목 차

Ⅰ. 개 요 1

1. 추진배경 1

2. 인공지능 활용 3

Ⅱ. 인공지능 모델 5

1. 인공지능 모델 개요 5

2. 인공지능 모델 구성요소 6

Ⅲ. 테스트 실무절차 19

1. 주요 전제사항 19

2. FAQ 20

3. 테스트결과서 예시 22

Ⅴ. 인공지능 모델 사례 26

Ⅰ. 개 요

1 추진배경

❑ AI 바우처 사업 핵심 전제사항

○ AI 바우처 사업은 인공지능 솔루션을 수요기업이 활용하는 데 있어 필요한 자금을 지원하는 사업으로 공급기업의 **인공지능 솔루션 및 모델 보유를 전제**하는 사업임

< 인공지능 솔루션 시험 대상 >

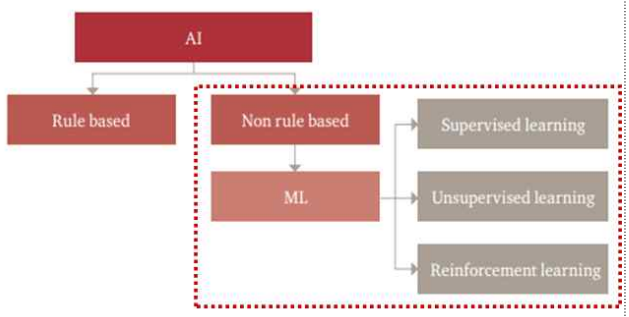

* 포괄적 인공지능 범주에서는 룰(Rule) 기반 시스템도 인공지능으로 포함되나 엄격한 의미에서 인공지능이 적용되었다 볼 수 없음

* AI 바우처 사업에서는 데이터를 통해 학습하는 **머신러닝 또는 딥러닝 인공지능 모델을 AI 솔루션 시험대상**으로 정의함

※ 사업기간 내 인공지능모델 완성을 전제함

❑ AI 바우처 공모안내서 관련 내용

○ 전담기관과 사업수행기관 간 계약서 성격의 **공모안내서**에는 사업기간내 **제3자 테스트 결과서를 필수 제출**하도록 정의하고 있음

< 2023년 AI 바우처 공모안내서 (24p) >

○ 공급기업이 제공하는 솔루션에 대해서는 사업기간 내 자체 시험결과가 아닌 제3자가 수행한 테스트 결과서*를 필수 제출해야 함

* 단, 제출 테스트 결과서에는 성능목표, 학습/테스트데이터, 사용 알고리즘, 사용언어, 개발프레임워크 등이 제시되어야 하며 KOLAS 인증 기업의 테스트결과서만 허용

** 기한 내 미제출 시 참여제한, 사업비환수 등 제재조치를 취할 수 있음

○ 관련하여, 공모안내서의 인정항목의 기타 경비에 **테스트 용역비가 추가**되어 공급기업은 사업비 내에서 테스트 수행에 따른 비용 집행이 가능(8p)

○ 반면, 수행기업들이 이해하는 인공지능 솔루션 및 모델의 범위에 대해 **이해도가 제각각**인 것이 현실이고 **모델 성능이 데이터에 종속적**이라는 점도 제약요소임

❑ 인공지능 모델 테스트가 어려운 이유

○ **(불충분한 데이터)** 모델 테스트를 위해서는 테스트 확보가 필수적인데, 충분한 훈련과 시험 데이터가 확보되지 않은 상태에서는 테스트는 불가능

* 학습용 데이터가 부족한 경우 데이터 생성기법(예: GAN)을 통해 증강(Augmentation)하거나 교차 검증기법을 통해 데이터 편향을 최소화하는 방안이 고려되어야 함

○ **(데이터 편향)** 편향된 데이터 샘플링을 통해 학습한 인공지능 모델은 편향된 결과를 산출할 수 밖에 없으므로 학습 시 데이터가 편향되지 않도록 해야 함

* 모집단 대비 소수 학습 데이터, 지도학습 레이블에 의해 편향, 업무 도메인별 데이터 특성/분포 미반영, 실환경에서 발생 하는 노이즈 제거에 많은 시간과 노력이 필요함

○ **(데이터 품질문제)** 결측치 또는 이상치가 있거나, 스케일이 다른 데이터들에 대해 정규화 처리가 되지 않은 낮은 데이터 품질에 의해 결과 왜곡 발생

○ **(목표 설정 문제)** 분류, 예측, 추천, 군집화 등 모델에 적합한 성능목표를 결정하지 않았거나 정확도(Accuracy)와 같이 데이터 분포나 편향에 종속적인 목표 설정

* 정확도(Accuracy)는 예측과 실제가 일치하는 경우의 비율을 나타내는데 훈련· 시험 데이터가 예측과 실제가 일치하는 비율이 높은 데이터가 많은 경우 그만큼 결과 왜곡

○ **(시험환경 미비)** 머신러닝 모델개발을 위한 자동화 도구(AutoML*) 등 도구활용, 모델 문서화, 테스트케이스 및 시험문서 탬플릿 등 시험을 위한 준비 미흡

* AutoML이란 기계학습 과정에서 알고리즘 탐색, 학습 하이퍼 파라미터 튜닝, 의미있는 특성 추출 작업, 전이학습 등 반복되는 수작업을 자동화하는 도구

< 머신러닝 자동화 도구 개념도 예시 >

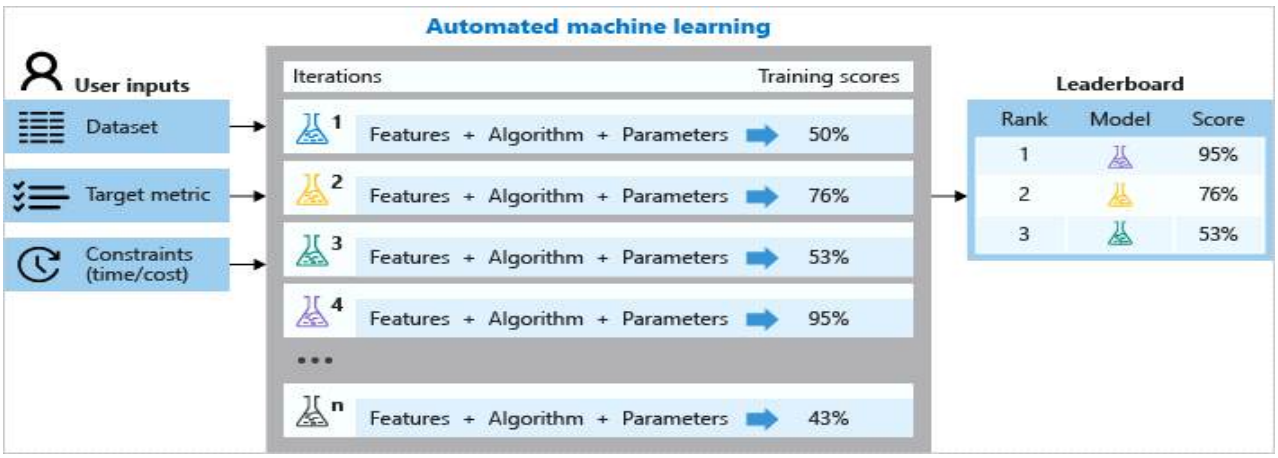

2 인공지능 활용

❑ 활용도에 따른 인공지능 모델 성숙도

ㅇ 인공지능 솔루션을 현장 **비즈니스 적용성**(X축)과 **기술 검증 커버리지**(Y축) 2가지 관점에서 분류할 경우 4가지 유형으로 분류될 수 있음

< 인공지능 솔루션 성숙도 분류 >

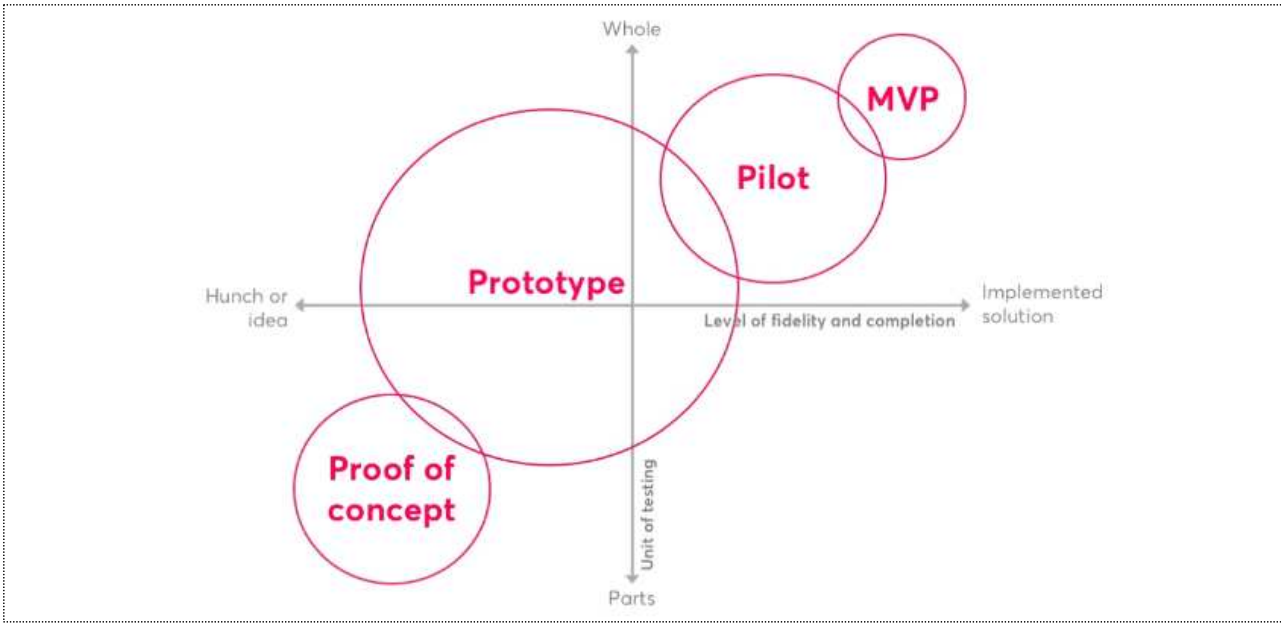

유형	특징
MVP	• Minimum Viable Product의 약자로 현장 적용이 즉시 가능한 제품을 의미 • 수요기업이 특별한 조건없이 검수가 가능한 단계 • 인공지능 솔루션은 요구사항을 충족하고 최적화된 상태
Pilot	• 현장에 적용하기 위해서는 모델 커스터마이즈나 튜닝 등 사전 작업 필요 • 수요기업이 현장에서 활용하기 위해서는 일정 수준의 유지보수 필요 • 인공지능 솔루션은 대다수 요구사항을 충족한 상태로 마무리가 필요한 상태
Prototype	• 현장에 적용하기 위해서는 상당 분량의 개발작업이 필요 • 수요기업이 현장에 활용하기는 어려운 단계 • 인공지능 솔루션은 일부 요구사항만 충족한 상태로 많은 개발이 필요한 상태
PoC	• Proof of Concept의 약자로 코드가 실존하지 않는 개념과 아이디어 상태 • 실제 인공지능 솔루션이 없고 문서로만 존재한 상태

ㅇ 인공지능 모델 테스트는 프로토타입에서 MVP 단계에 있는 모델을 대상으로 **성능목표(Metric) 달성도**를 통해 기술 성숙도를 검증하는 데 목적이 있음

❑ MVP 구현을 위한 체계

ㅇ 인공지능 솔루션을 현장에 성공적으로 활용하여 성과를 창출하기 위해서는 **전략 수립, 반복적 모델 개발, 업그레이드·환류**에 대한 체계가 정교하게 정립되어야 함

< 인공지능 활용 프로세스 (출처 : PwC) >

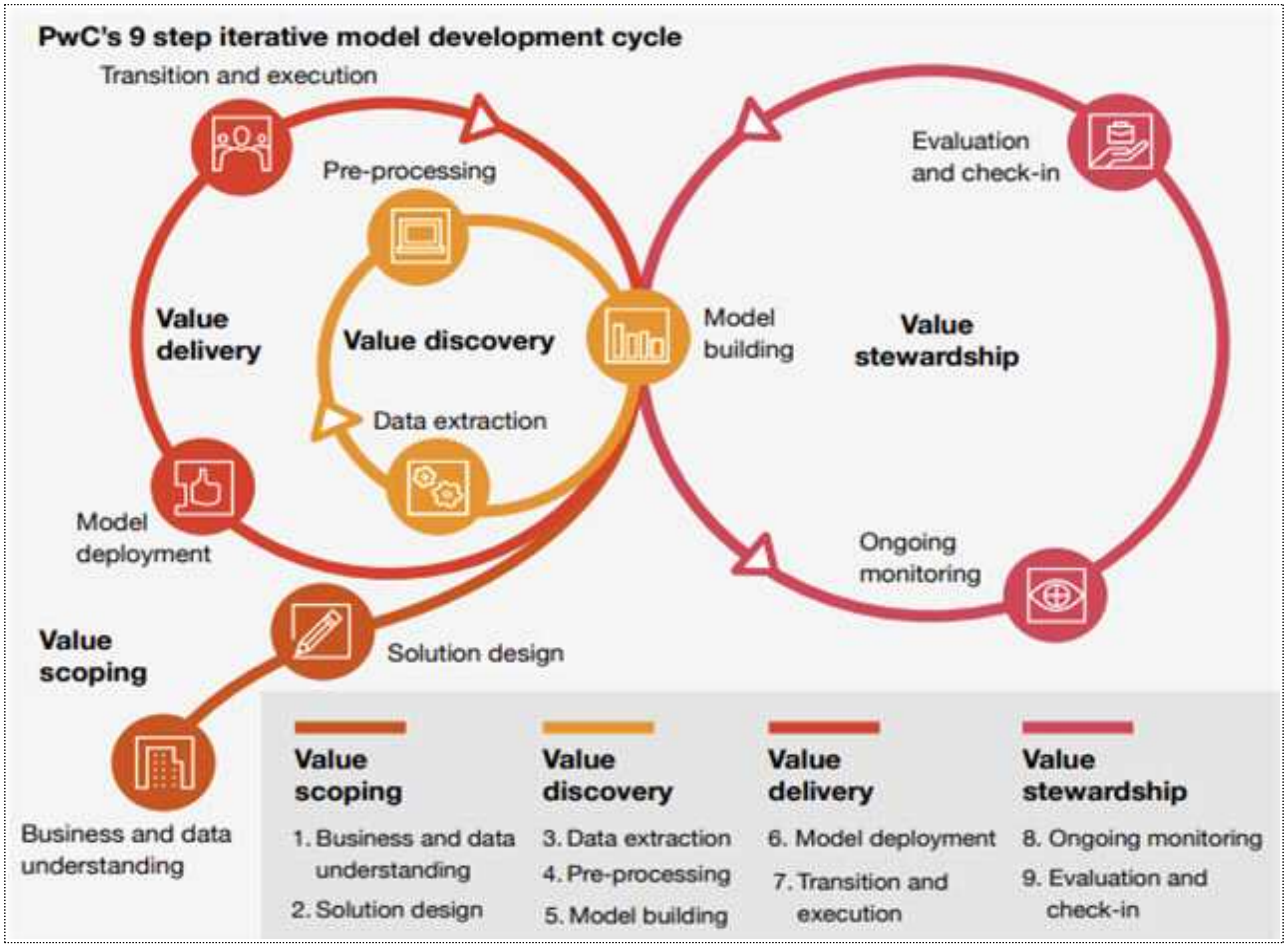

유형	특징
전략 설정 (Value Scoping)	• 기업전략, 비즈니스 목표와 데이터 이해, 관련 규제검토, 이행조직, • 솔루션 설계 및 프레임워크 선택
모델 개발 (Value Discovery)	• 벤더선택 및 관리, 데이터 관리(데이터 획득/추출/전처리) • 시스템 설계, 모델 빌드(모델훈련/검증/튜닝/시험)
모델 납품 (Value Delivery)	• 모델 전개, 현장 적용 및 활용
환류 이행 (Value Stewardship)	• 지속적 모니터링(사이버 보안, 데이터 품질, 규제, 성능개선) • 인공지능 모델 변경과 테스트(주요기능, 경미변경, 데이터변경)

ㅇ MVP는 수요기업의 솔루션 활용과 데이터에 대한 **전략적 이해도**가 높고 공급기업 솔루션의 핵심요소인 **모델의 완성도**가 있으며 **환류 계획이 구체적**인 점이 특징

Ⅱ. 인공지능 모델

1 인공지능 모델 개요

❑ AI 바우처 인공지능 개념

ㅇ 인공지능은 인간의 지각활동을 모사하는 기술로 학습의 방법을 불문하여 이런 이유로 **룰(Rule) 기반의 소프트웨어**도 포괄적으로 인공지능이라 해석되기도 함

ㅇ 인공지능 중 **데이터를 통해 학습할 수 있는 기술**을 머신러닝 또는 기계학습이라 하고 머신러닝 중 입력과 출력을 학습 데이터로 제공하면 **지도학습**이라 하고 입력만 제공하면 **비지도학습**이라 하며 **머신러닝 중 뉴럴네트워크를 사용하면 딥러닝**이라 함

ㅇ AI 바우처 사업에서는 인공지능을 포괄적으로 해석하지 않고 **인공지능 모델이 존재**하는 **머신러닝과 딥러닝 알고리즘에 기반한 솔루션**을 **인공지능 솔루션**으로 정의함

< 인공지능 개념도 >

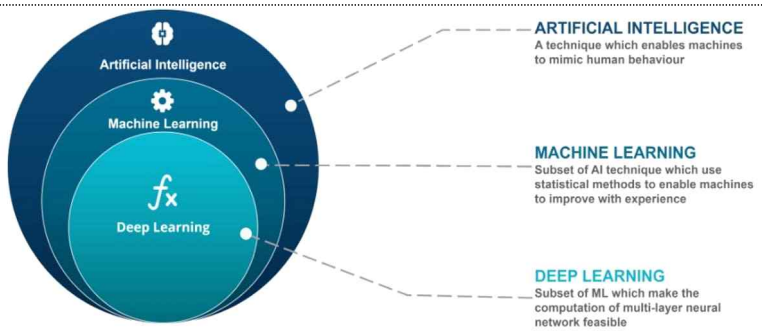

❑ 과소적합(Underfitting) & 과대적합(Overfitting)

ㅇ 인공지능 모델은 학습데이터 종속성이 없는 단순한 모델로 편차(Bias)가 큰 **과소적합**이 있고 종속성이 큰 복잡한 모델로 분산(Variance)가 큰 **과대적합**이라 함

< 인공지능 모델의 적합도 >

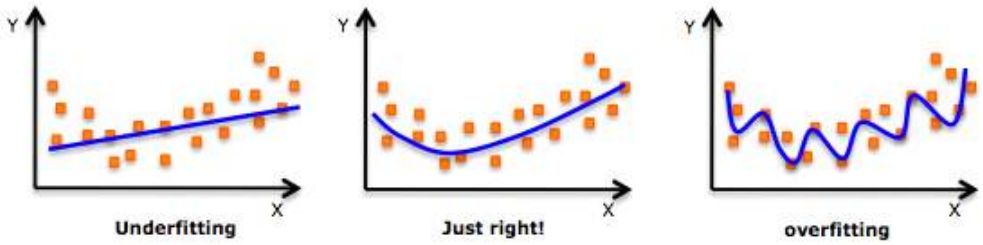

2 인공지능 모델 구성요소

인공지능 솔루션의 핵심 구성요소인 인공지능 모델이 최적적합으로 구현되어 있는지 검증하기 위해서는 **데이터 확보/정제**, 인공지능 **모델 최적화, 적절한 매트릭** 선정이 필수적임

구성요소	내용	
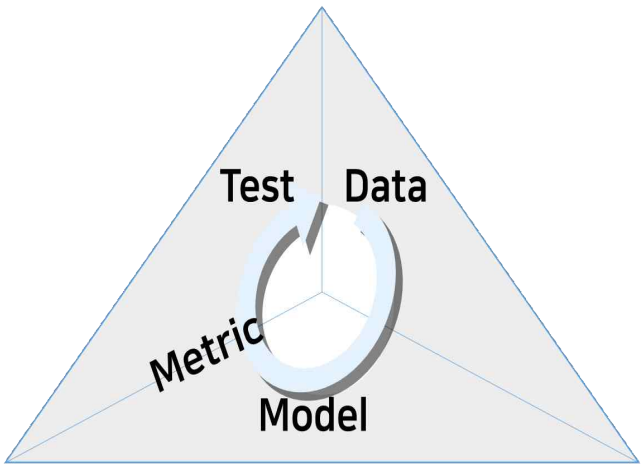	**Data**	• 목표에 맞는 Data 수집 • Feature Engineering • Cross Validation • 학습, 검증, 평가 데이터 분류 • Data 정제 및 희소 데이터 문제 해결 • 데이터 가공 품질 확보
	Model	• 목표에 맞는 모델 선정 및 성능 향상 방법 • 앙상블 기법 • 하이퍼파라메터 • 과소적합 해결 • 과대적합 해결
	Metric	• 인공지능 모델 성능 평가 지표 • 유즈 케이스별 성능 평가 지표
	Test	• 인공지능 모델의 목표에 맞는지 성능 평가 • 데이터, 매트릭, 모델의 적합성 확인

1 데이터 (Data)

ㅇ 인공지능 모델 개발 시 사용할 데이터를 수집하고 정제, 라벨링하는 작업이 절대적으로 중요

ㅇ 데이터는 Quality(품질)와 Quantity(양)이 중요

방법	내용
Quality (품질)	• 데이터의 질은 데이터가 얼마나 모델을 잘 설명할 수 있는지 보여줌 • 인공지능 모델의 목적성에 부합된 데이터 품ㅋ질 확보가 중요, 데이터의 적합성, 정확성, 유효성 확보 • 품질에 따른 문제점 : 데이터 셋의 오류, 데이터 편향성, 모델 가정의 오류 등
Quantity (양)	• 아무리 선정한 데이터 모델을 설명한다고 하더라도 충분한 데이터가 없다면 현실을 잘 반영하지 못하는 모델이 될 수 있음 • 적은 데이터로는 인공지능 모델의 신뢰성 하락, 데이터 양이 적은 경우 표본이 모집단을 대표하지 못함

ㅇ 데이터 구축은 원천데이터 수집, 데이터 전처리, 데이터 저장, 라벨링이나 데이터큐레이션과 정제, 데이터 검토 및 업데이트을 통해 인공지능 모델 개발에 사용

❑ 피처 엔지니어링 (Feature Engineering)

ㅇ 결측치, 이상치 등 데이터 품질문제 해결과 서로 다른 분포를 가지는 데이터 보정 작업 등을 피처엔지니어링(Feature Engineering)이라 함

< 피처 엔지니어링 개념도 >

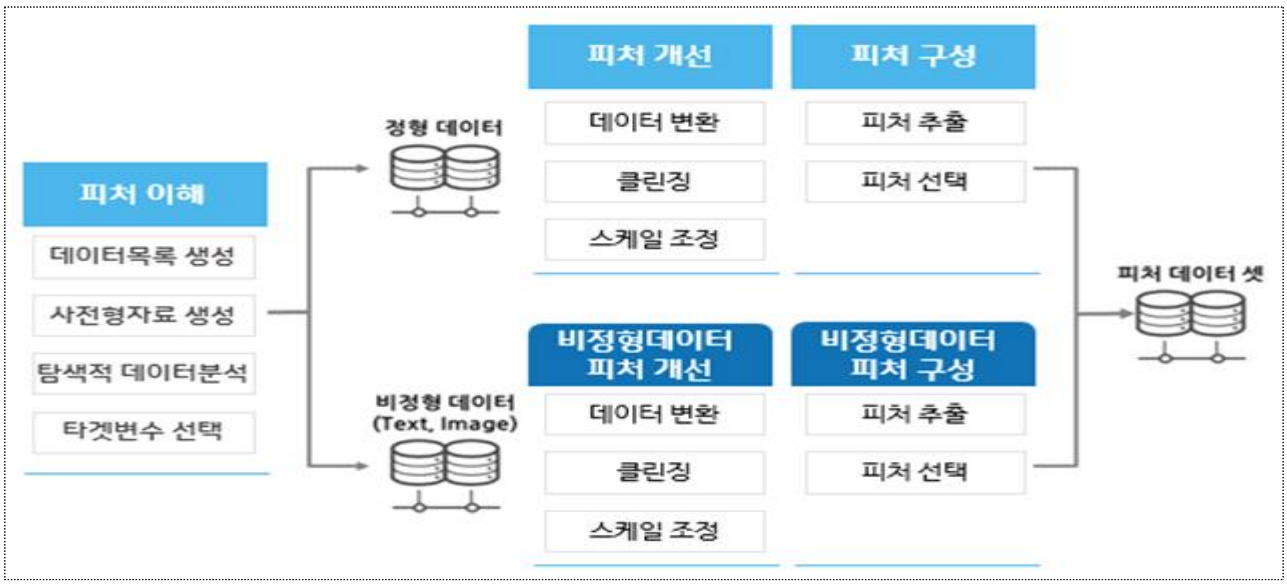

< 피처 엔지니어링 예시 >

방법	내용
결측치 보정	• 결측값은 데이터에 값이 없는 경우를 말하며, 가장 간단하게는 평균(Mean), 중앙값(Median), 최빈값(Mode)으로 채울 수 있으며 결측값이 너무 많은 경우 해당 피처를 삭제(Drop)할 수 있음 • 초기값(Default) 값이나 빈번하게 나타나는 값 또는 랜덤 값으로 채울 수 있음
이상값 처리	• 값이 존재할 수 있는 범위를 벗어나는 경우, 표준편차에서 예외적으로 나타내는 값들을 삭제하거나, 특정 Percentage외에 있는 값들을 삭제(상위 5% 또는 하위 5% 등)하여 처리
범주화 (Bining)	• Binning은 근처의 값들을 하나의 범주로 묶게되면 좀더 견고한 모델을 얻게 되는데 예건테 40에서 50, 50에서 60, 60 이상 등 구간을 정해 그룹으로 처리
원-핫 인코딩 (One-Hot Encoding)	• 텍스트로 된 범주형 데이터를 학습에 이용하기 위해서는 숫자 타입으로 변형이 필요한데, 서울(1), 부산(2), 대전(3)으로 범주화하면 대전이 서울보다는 2보다 큰 무엇인가로 오해할 가능성이 생기기 때문에 데이터를 하나의 컬럼으로 만들고 해당 값이 있는지를 0과 1로 표현하는 방법
피처 스케일링 (Feature Scaling)	• 서로 다른 범위의 데이터들을 같은 범위로 묶어 학습하기 위해 데이터 범위를 0과 1 사이로 변환(정규화) • Normalization($\frac{x - x_{min}}{x_{max} - x_{min}}$), Standardization($\frac{x-\mu}{\sigma}$ $(\mu : 평균, \sigma : 표준편차)$)
로그 변형	• 나이와 재산의 관계를 볼 때, 나이는 1~100까지의 범주를 갖지만, 재산은 0원에서 수조원까지 아주 넓게 분포할 수 있어 이런 데이터를 정규분포에 맞게 변형 시켜주는 것이 로그변환(Log-Transform)

❑ 교차 검증 (Cross Validation)

ㅇ 훈련(Train)과 시험(Test) 데이터로만 학습을 한 모델은 시험 데이터에 과대 적합할 수 있어 훈련 데이터 중 일부 데이터를 검증목적으로 활용하는 기법

* 다양한 상황이 있기 때문에 훈련 데이터 중 검증(Validation) 데이터 비중에 대한 정답은 없으나 훈련 대 검증 데이터 비중을 8:2 내외로 하는 경우가 다수

ㅇ 아래의 경우는 데이터를 5개의 부분집합으로 분할(K=5라 표현)한 후 각 분할마다 하나의 폴드를 시험용으로 사용하고 나머지 4개는 훈련용으로 사용

* 이러한 학습과정을 반복하여 각 분할마다 정확도를 높이게 됨

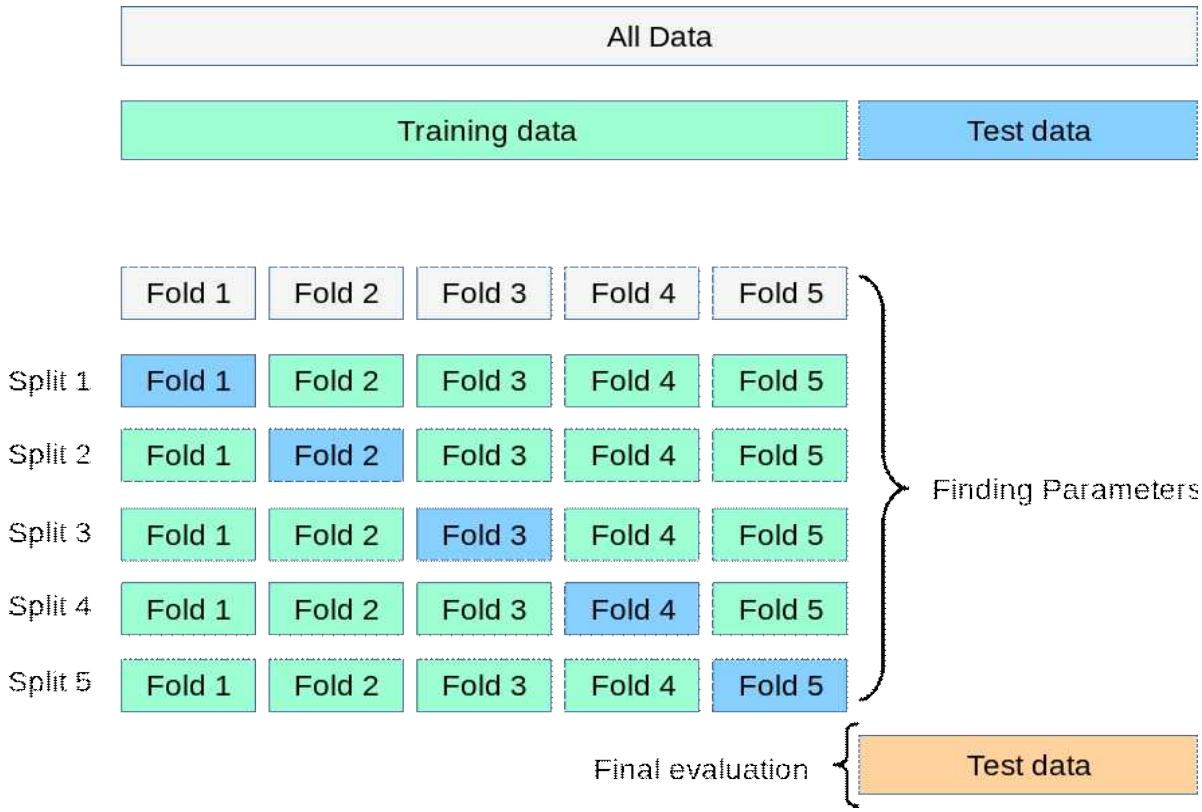
All Data
Training data
Test data
Fold 1
Fold 2
Fold 3
Fold 4
Fold 5
Split 1
Split 2
Split 3
Split 4
Split 5
Finding Parameters
Final evaluation
Test data

2 모델 (Model)

❑ 앙상블 (Ensemble)

ㅇ 앙상블 학습(Ensemble Learning)은 여러 개의 분류기를 생성하고, 그 예측을 결합함으로써 보다 정확한 예측을 도출하는 기법

* 하나의 강력한 알고리즘보다 복수의 약한 알고리즘이 더 뛰어날 수 있다는 가정에 기반

< 앙상블 학습 유형 >

<table>
<tr><th>학습 유형</th><th>내용</th><th>개념도</th></tr>
<tr><td>보팅(Voting)</td><td>• 서로 다른 알고리즘의 모델들의 결과 중 다수의 결과를 최종 판단의 근거로 활용
<table><tr><td>하드 보팅
(Hard Voting)</td><td>분류 모델별 결과 중 다수결과를 채택하는 방식으로 모델1(고양이), 모델2(개), 모델3(개)인 경우 개로 판정</td></tr><tr><td>소프트보팅
(Soft Voting)</td><td>만약 모델1이 고양이 판정을 99%로 했고 모델2와 3은 개 판정을 51%로 했다면 소프트보팅은 판정확률에 가중치를 부여하여 고양이로 판정</td></tr></table></td><td> 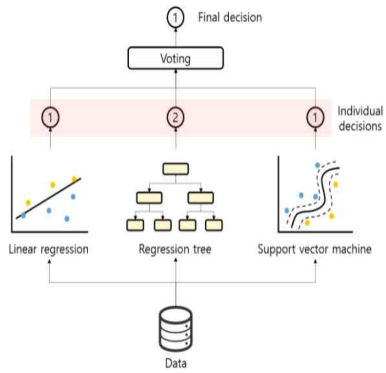
</td></tr>
<tr><td>배깅(Bagging)</td><td>• 각각의 샘플(Bootstrap)을 여러 번 뽑아(Bootstrap) 각 모델을 학습시켜 결과를 집계(Aggregation)하는 방법
• 모두 같은 유형의 알고리즘을 사용하며, 대표적인 방식은 랜덤 포레스트(Random Forest) 방식</td><td> 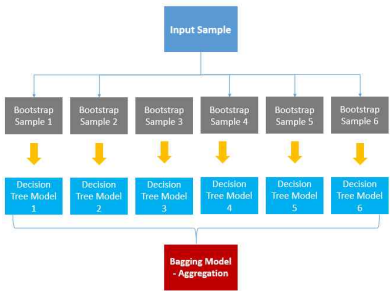
</td></tr>
<tr><td>부스팅
(Boosting)</td><td>• 여러 개의 약한 학습기(Week Learner)를 순차적으로 학습, 예측하면서 잘못 예측한 데이터에 가중치를 부여해 오류를 개선하는 학습 방식
• 배깅은 병렬로 학습하고, 부스팅은 순차적으로 학습하여 속도가 느린 반면 오류가 적음
• 대표적인 부스팅 알고리즘으로는 AdaBoot, GBM, XGBoost, LightGBM, CatBoost</td><td> 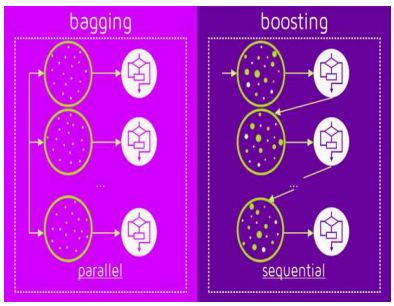
</td></tr>
<tr><td>스태킹
(Stacking)</td><td>• 여러 모델들을 활용하여 각각의 예측 결과를 도출한 뒤 그 예측 결과를 결합해 최종 예측 결과를 만들어내는 방법</td><td> 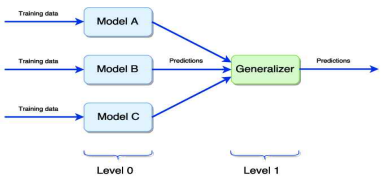
</td></tr>
</table>

❑ 하이퍼파라미터 (Hyperparameter)

ㅇ 최적의 딥러닝 모델 구현을 위해 학습률, 배치크기, 훈련 반복 횟수, 가중치 초기화 방법 등 **인간의 선험적 지식을 기반**으로 딥러닝 모델에 설정하는 변수

* 다양한 하이퍼파라미터가 존재하고 최적의 딥러닝 모델 생성을 위해 하이퍼파라미터 튜닝이 필수적

< 인공지능 하이퍼파라미터 개념 >

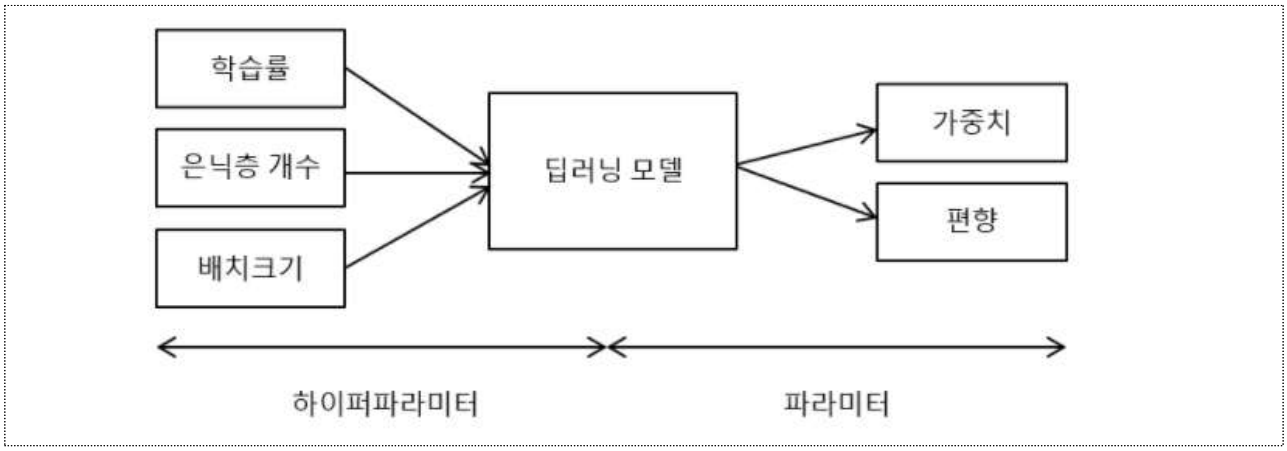

비교 항목	하이퍼파라미터	딥러닝 모델의 파라미터
사용 목적	모델링 최적화 파라미터값 도출	최적화된 딥러닝 모델 구현
생성 주체	사용자 판단 기반 생성	데이터 학습 모델이 생성
조정 여부	조정 가능	임의 조정 불가
활용 사례	– 학습률 – 경사하강법 반복 횟수 – 활성화 함수	– 인공신경망의 가중치 – SVM의 Support Vector – 선형회귀에서의 결정계수

* 파라미터는 딥러닝 모델에 의해 결정되지만 하이퍼파라미터는 휴리스틱 기반 사람이 직접 설정

* 하이퍼파라미터는 데이터 분석 결과로 얻어지는 값이 아니므로 절대적인 최적값은 존재하지 않음

< 인공지능 모델 파라미터 예시 >

종류	설명	적용 시 고려사항
학습률 (Learning Rate)	gradient의 방향으로 얼마나 빠르게 이동할 것인지 결정하는 변수	너무 작으면 학습의 속도가 늦고, 너무 크면 학습 불가
손실 함수 (Cost Function)	입력에 따른 기대 값과 실제 값의 차이를 계산하는 함수	평균 제곱 오차 교차 엔트로피 오차
정규화(일반화) 파라미터 (Regularization parameter)	과적합(Overfitting)문제 회피 위해 L1 또는 L2 정규화 방법 사용	사용하는 일반화 변수도 하이퍼 파라미터로 분류
미니 배치 크기	배치셋 수행을 위해 전체 학습	가용 메모리 크기와 epoch*

종류	설명	적용 시 고려사항
(Mini-batch Size)	데이터를 등분하는(나누는) 크기	수행 성능을 고려
훈련 반복 횟수 (Training Loop)	학습의 조기 종료를 결정하는 변수	학습 효율이 떨어지는 시점을 적절히 판단
은닉층의 뉴런 개수 (Hidden Unit)	훈련 데이터에 대한 학습 최적화 결정 변수	첫 Hidden Layer의 뉴런 수가 Input Layer 보다 큰 것이 효과적
가중치 초기화 (Weight Initialization)	학습 성능에 대한 결정 변수	모든 초기값이 0일 경우 모든 뉴런이 동일한 결과

* epochs(에포크) : 에포크는 같은 데이터셋으로 문제를 반복적으로 풀어보는 학습 방법으로 가중치를 갱신하면서 학습하며 같은 문제라도 학습상태(가중치)가 다르기 때문에 추가학습 가능

< 하이퍼파라미터 튜닝 기법 >

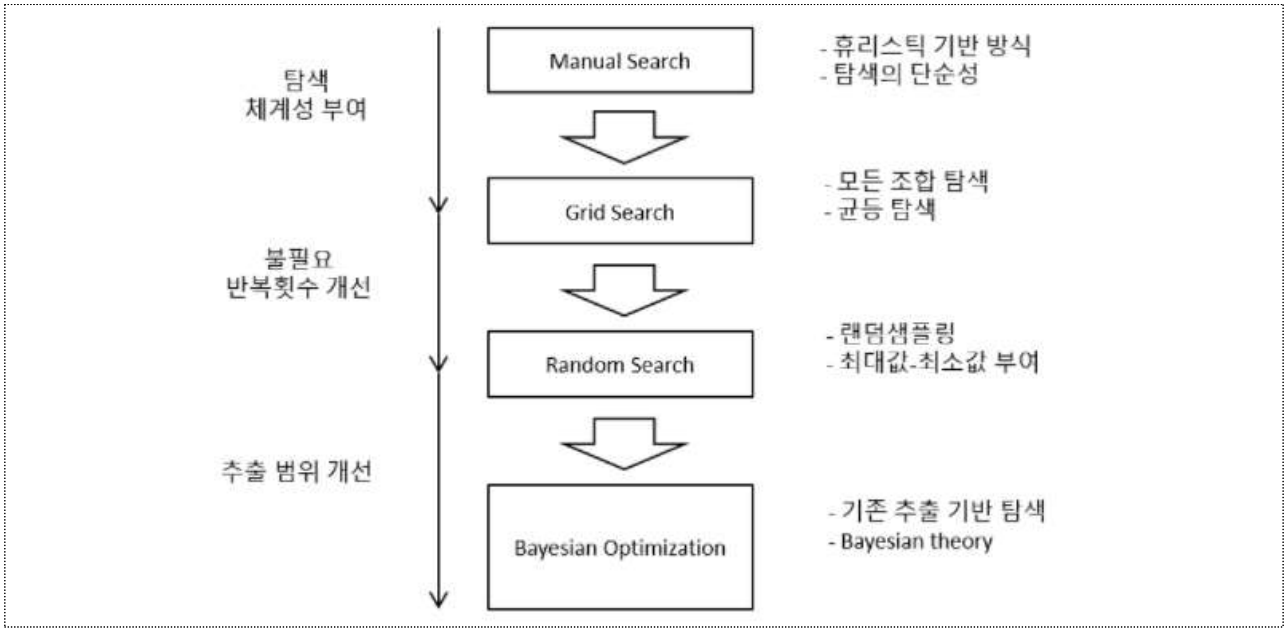

튜닝 기법	주요 활동	적용 방안
Manual Search	휴리스틱 조합	사용자의 직관과 경험 기반 탐색
	탐색의 단순성 적용	사용자 도출 조합 중 최적 조합 적용
Grid Search	모든 조합 탐색	하이퍼파라미터 적용값 전체 탐색
	시행 횟수 한계 파악	하이퍼파라미터 증가로 인해 전수 탐색 한계
Random Search	랜덤 샘플링	범위 내 무작위 값 반복 추출
	탐색 범위 부여	하이퍼파라미터 최소/최대값부여
Bayesian Optimization	관측 데이터 기반 F(x) 추정	베이즈 정리 확용, 가우시안 프로세스
	함수 생성	확률 추정 결과 기반 입력값 후보 추천 함수

* 학습의 규모가 커질수록 탐색 시간 기반 Bayesian Optimization이 가장 뛰어나지만, 생성 모델 수준을 고려하여 상황에 맞는 튜닝 방법 선택이 필요

* 하이퍼 파라미터의 적절한 튜닝을 통해 최적의 딥러닝 파라미터 도출 가능

3 매트릭 (Metric)

❑ 오차행렬 (Confusion Matrix)

ㅇ 오차행렬이란 학습을 통한 예측 성능을 측정하기 위해 예측 값과 실제값을 비교하기 위한 표로서 인공지능 분류 모델 매트릭 산정을 위한 기준 데이터

* 의료판독 AI가 질병을 양성으로 예측하고 실제 환자가 양성이라면 True Positive가 됨

구분		인공지능 학습모델 예측 값	
		Positive	Negative
실제 값	Positive	True Positive (TP, 정답)	False Negative (FN, 오답)
	Negative	False Positive (FP, 오답)	True Negative (TN, 정답)

❑ 오차행렬 기반 인공지능 분류모델 매트릭

매트릭	내용	산식
Accuracy (정확도)	• 인공지능 모델의 성능을 직관적으로 나타내는 지표로서 인공지능 모델이 True를 True라고 예측한 경우와 False를 False라고 예측한 정답의 비율 • 정확도는 데이터 분포에 크게 좌우되는데 만약 99% 데이터가 True인 상황에서 인공지능이 전체를 True라고 하는 경우 성능과 무관하게 매트릭 결과가 99%가 됨 • 오차행렬의 대각선 부분에 해당	TP FN FP TN $(Accuracy) = \frac{TP + TN}{TP + FN + FP + TN}$
Error Rate (오류율)	• 전체 중 오답 예측 비율 • 정확도와 반대되는 수치	$(Error\ Rate) = \frac{FP + FN}{TP + TN + FN + FP}$
Recall (재현율)	• 실제 Positive 중 인공지능 모델이 Positive로 찾은 비율 • 인공지능이 Positive를 찾을 수 있는 능력을 나타냄 • 오차행렬의 상단 행방향에 해당되며 Sensitivity(민감도) • 예) 질병이 있는 사람 중 질병이 있다고 판정받을 확률	TP FN FP TN $(Recall) = \frac{TP}{TP + FN}$
Specificity (특이도)	• 전체 Negative 중 인공지능이 Negative로 찾은 비율 • 인공지능이 Negative를 찾을 수 있는 능력을 나타냄 • Positive를 찾는 능력을 계산하는 재현율과 달리 특이도는 Negative를 찾는 능력 • 예) 질병이 없는 사람 중 진짜 질병이 없다고 판정받을 확률 • 오차행렬의 하단 행방향에 해당	$Specificity = \frac{TN}{TN + FP}$
Precision (정밀도)	• 모델이 Positive라 분류한 것 중 실제 Positive 비율 • 인공지능의 Positive 판정에 대한 신뢰도를 나타냄 • 오차행렬의 열방향에 해당	TP FN FP TN

매트릭	내용	산식
		$(Precision) = \frac{TP}{TP + FP}$
F1 Score	• 분류대상 데이터 분포가 고르지 못한 경우 학습 데이터 분포에 따라 Accuracy(정확도) 수치가 왜곡될 수 있어 재현율과 정밀도 조화평균인 F1 Score를 사용	$(F1\text{-}score) = 2 \times \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \times \frac{Precision \times Recall}{Precision + Recall}$ 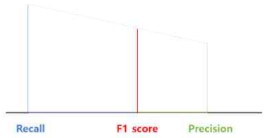

< 다중 클래스에서 F1 Score 산정 예시 >

- 인공지능 모델1과 모델2가 200개 데이터를 4개(A 200개, B 10개, C 10개, D 10개) 클래스로 분류한다고 할 경우 정확도를 기준하게 되면 A 데이터가 다수를 차지하고 있으므로 A 분류 정답률만 우수함에도 불구하고 모델2(0.87)가 모델1(0.57)에 비해 높은 정확도를 나타냄
- F1 Score를 사용하게 되면 클래스별 재현율과 정밀도를 각각 계산하여 평균하고 이를 하나의 수치로 표현(조화평균)하므로 전체적인 클래스 분류 정확도를 고르게 반영할 수 있음

Model 1

predictions (output) →

actual class (input) ↓	A	B	C	D
A	100	80	10	10
B	0	9	0	1
C	0	1	8	1
D	0	1	0	9

Precision ↓

Recall →

Accuracy = (100+9+8+9) / 230 = 0.547

- Precision A =100 / (100+0) = 1
- Precision B = 9 / (9+81) = 9/91
- Precisian C = 8 / (8+10) = 8/18
- Precision D = 9 / (9+12) = 9/21

average precision = 0.492

- recall A =100 / (100+100) = 100/200
- recall B = 9 / (9+1) = 9/10
- recall C = 8 / (8+2) = 8/10
- recall D = 9 / (9+1) = 9/10

average recall = 0.775

F1 Score = 2 * ((0.492*0.775) / (0.492+0.775)) = 0.601

Model 2

predictions (output) →

actual class (input) ↓	A	B	C	D
A	198	2	0	0
B	7	1	0	2
C	0	8	1	1
D	2	3	4	1

Accuracy = (198+1+1+1) / 230 = 0.87

- Precision A =198 / (198+9) = 198/207
- Precisian B = 1 / (1+13) = 1/14
- Precisian C = 1 / (1+4) = 1/5
- Precision D = 1 / (1+3) = 1/4

average precision = 0.369

- recall A =198 / (198+2) = 198/200
- recall B = 1 / (1+9) = 1/10
- recall C = 1 / (1+9) = 1/10
- recall D = 1 / (1+9) = 1/10

average precision = 0.323

F1 Score = 2 * ((0.369*0.323)/(0.369+0.323)) = 0.344

❑ PR (Precision-Recall) & mAP (mean Average Precision)

ㅇ PR 그래프는 **특정 알고리즘의 성능을 전반적으로 파악**하기에는 좋으나 서로 다른 두 알고리즘의 성능을 정량적으로 비교하기에는 한계*

* 이를 보완하기 위해 나온 개념이 클래스 AP 평균인 mAP(mean average precision)으로 다수의 컴퓨터비전 분야 물체인식 알고리즘의 성능은 AP(Average Precision)으로 평가

< PR(Precision-Recall) 그래프 >

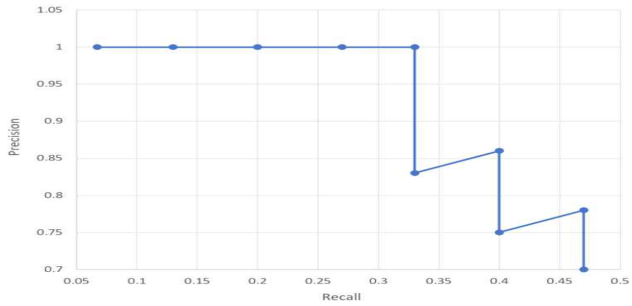	• 정밀도(Precision)과 재현율(Recall)은 반비례 관계로 두 지표 성능 변화 전체를 확인할 필요가 있고 이를 위해 PR 그래프를 이용함 • PR 곡선에서 x축은 recall 값이고, y축은 precision값으로 recall 값의 변화에 따른 precision값을 확인하여 전체적 성능 확인

❑ AUROC (Area Under the ROC Curve)

○ Positive Rate 기준으로 100% TPR(True Positive Rate)이고 0% FPR(False Positive Rate) 인 경우 ROC 그래프의 면적은 1이되며, 최소값은 0.5가 됨

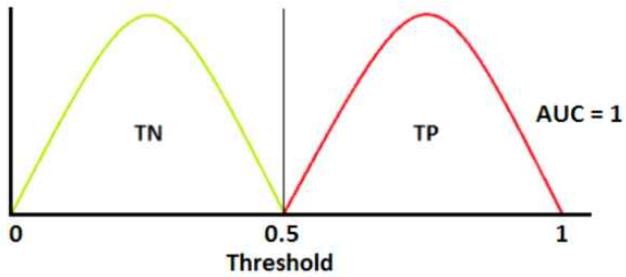	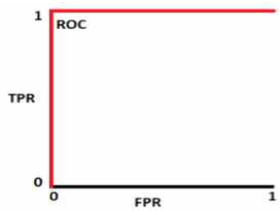	• 양성과 음성을 모두 정확히 분류되었기 때문에 오류로 인한 교집합은 없고 이 경우 AUC 면적은 1
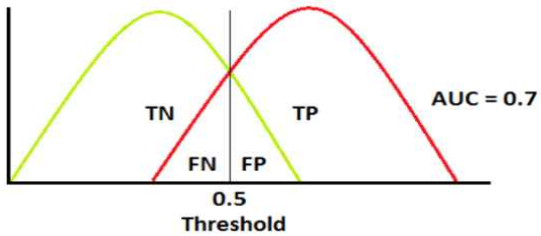	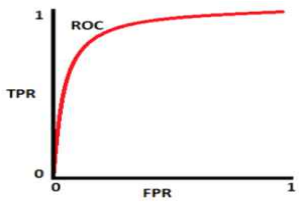	• 양성과 음성 판정에 일부 오류가 있고 이 경우 AUC 면적은 0.5와 1사이가 됨
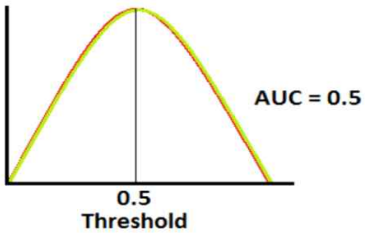	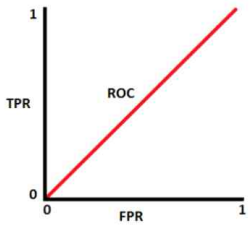	• 양성과 음성판정이 부정확한 상태로 AUC 면적은 최소값인 0.5가 됨

❑ 예측모델 매트릭

ㅇ 예측모델은 예측한 값과 실제값의 편차를 구하여 성능을 측정

매트릭	내용	산식
R2 Score (R-Squared)	• 데이터의 분산에 비례한 에러 값을 표현	$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_{pred} - y_{exp})^2}{\sum_{i=1}^{n}(y_{exp} - y_{mean})^2}$ $R^2 = \frac{\text{예측분산}}{\text{실제분산}}$
RMSE/RMSLE [Root Mean Square(Log) Error]	• 데이터와 예측값 간의 차이를 통해 예측력을 평가 – 예측값과 정답값 간의 표준편차	$RMSE: \sqrt{\frac{\sum_{i=1}^{n}(y_{pred} - y_{exp})^2}{n}}$
MAE(Mean Absolute Error)	• 데이터와 예측값 간의 차이를 통해 예측력을 평가 – 예측값과 정답값 간의 편차	$MAE: \frac{1}{n}\sum_{i=1}^{n}\lvert y_{pred} - y_{exp}\rvert$

❑ 영상인식

매트릭	내용	산식
IoU(Intersection over Unit)	• 두 영역의 교차 영역의 넓이를 합 영역의 넓이로 나눈 값으로, 객체 검출에서 예측된 경계 상자의 정확도를 평가하는 지표 중 하나 • 예측된 경계 상자와 실제 참값(Ground Truth) 경계 상자의 IoU를 해당 경계 상자의 정확도로 간주 • 일반적으로 0.5 이상으로 제대로 검출(TP)되었다고 판단하며, 0.5 미만이면 잘못 검출(FP)되었다고 판단	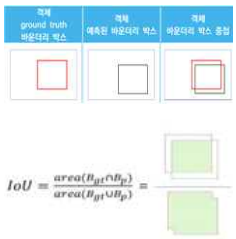

❑ 기계번역

매트릭	내용	산식
BLEU(Bilingual Evaluation Understudy)	• 기계번역 결과와 사람이 직접 번역한 결과가 얼마나 유사한지 비교하여 번역에 대한 성능을 측정하는 방법이며, 측정 기준은 n-gram(단어 개수 카운트)에 기반	$BLEU = \min\left(1, \frac{\text{output length(예측 문장)}}{\text{reference length(실제 문장)}}\right)\left(\prod_{i=1}^{4} precision_i\right)^{\frac{1}{4}}$
ROUGE(Recall-Oriented Understudy for Gisting Evaluation)	• 텍스트 요약 모델의 성능 평가 지표로서 모델이 생성한 요약본 혹은 번역본을 사람이 미리 만들어 놓은 참조본과 대조해 성능 점수를 계산	(예) ROUGE-N: unigram, bigram, trigram 등 문장 간 중복되는 n-gram을 비교하는 지표
TF-IDF(Team Frequency-Inverse Document Frequency)	• TFTF(단어 빈도, term frequency)-IDF(역문서 빈도, inverse document frequency) 값이 높다면 다른 문서에는 많지 않고 해당 문서에서 자주 등장하는 중요 단어를 의미	TF-IDF = TF X IDF

❑ 음성인식

매트릭	내용	산식
WER(Word Error Rate)	• 단어의 오류율을 측정하는 지표 • 잘못 식별된 단어는 다음의 세 가지 범주로 분류 - 삽입(I) : 가설에 잘못 추가된 단어 - 삭제(D) : 가설에서 감지되지 않은 단어 - 대체(S) : 참조와 가설 사이에서 대체 된 단어	$WER = \frac{I+D+S}{N} * 100\%$
CER (Character Error Rate)	• 글자의 오류율을 측정하는 지표로 주로 조사를 사용하는 언어에 사용 • 인식률 = 100% - CER	CER(%) = 100 X [1 - (탈자 개수 + 오자 개수 + 첨자 개수) / 원본 글자수]

❑ 군집(Clustering)

매트릭	내용	산식
Silhouette Score	• 특정점(i)에서 인접한 클러스터의 모든 점과의 거리 평균(b(i))와 동일 클러스터내 모든 점과의 거리평균(a(i))의 차이를 a(i)와 b(i) 중 큰 값으로 나눈 지표 • a(i)=0 이면 최대값 1, b(i)=0이면 최소값 –1 이며, 0.5보다 큰 값일 경우 결과가 타당한 것으로 평가됨	$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$
Dunn Index	• 군집간 거리 최소값을 군집내 거리 최대값으로 나눈 지표로 밀집되고 군집간 거리가 멀수록 커짐	$I(C) = \frac{\min_{i \neq j}\{d_c(C_i, C_j)\}}{\max_{1 \leq l \leq k}\{\triangle(C_l)\}}$

❑ GAN (Generative Adversarial Network)

매트릭	내용	산식
IS(Inception Score)	• IS는 GAN의 성능을 측정하기 위해 생성된 이미지의 Quality와 Diversity 두 가지 기준을 고려 • IS가 높을수록 좋은 성능을 낸다고 해석할 수 있음	$IS(G) = \exp(\mathbb{E}_{\mathbf{x} \sim p_g} D_{KL}(p(y\|\mathbf{x}) \| p(y)))$
FID(Frechet Inception Distance)	• Inception Network의 중간 레이어에서 Feature를 가져와 이를 활용함 • 실제 데이터의 분포를 활용하지 않는 단점을 보완해 실제 데이터와 생성된 데이터에서 얻은 Feature의 평균과 공분산을 비교하는 식으로 구성 • IS보다 Noise에 강하며, 낮을수록 좋은 성능을 낸다고 해석할 수 있음	$FID(x, g) = \|\mu_x - \mu_g\|_2^2 + Tr(\Sigma_x + \Sigma_g - 2(\Sigma_x \Sigma_g)^{\frac{1}{2}})$

4 테스트 (Test)

❑ 인공지능 모델 테스트 절차

ㅇ 인공지능 제품 품질은 인공지능 모델 성능 지표 달성과 소프트웨어 제품 자체의 기능적합성 등을 통칭하며 본 가이드에서는 **인공지능 모델로 대상을 국한**함

< 인공지능 모델 기능 테스트 프로세스 >

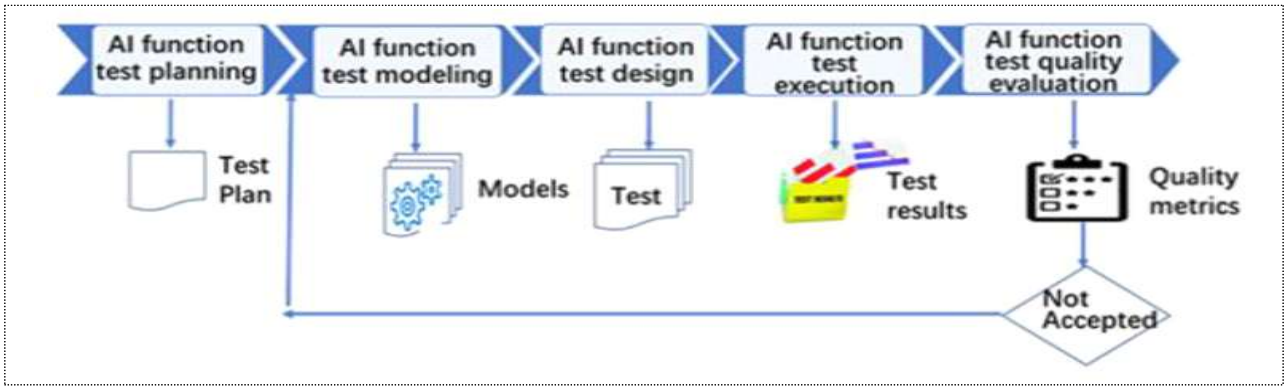

단계	내용
테스트 계획	• 인공지능 기능 식별, 분류하고 기능 요구사항에 대해 구체화하여 정의 • 테스트 대상 모델과 매트릭 정의
테스트 모델링	• 시험 데이터 교차검증, 시험도구 선택, 인프라 시험환경 계획
테스트 설계	• 시스템 입력(텍스트, 이미지, 오디어, 영상)과 출력에 기반한 테스트케이스 상세 설계
테스트 실행	• **시험환경 점검, 테스트케이스 실행, 시험결과 기록, 시험성적서 제출 등 테스트 실행**
결과검토	• **테스트 범위가 충분하고 결과가 품질목표를 달성하였는지 평가**

ㅇ (테스트결과서) 사업수행기업이 스스로 제3자 테스트 결과서 제출해야하며, 이 때 KOLAS 인증 기업의 테스트 결과서만 허용

* 테스트 수행에 필요한 경비에 대해서는 기타 경비로 사업비(용역) 집행 가능하며 시험성적서는 테스트결과서 제출 목적 외 전담기관의 인증 등을 의미하지는 않음에 유의

Ⅲ. 테스트 실무절차

1 주요 전제사항

❑ 공모안내서에 명시된 바와 같이 사업기간 내 의무 제출

- AI 바우처 사업은 공모안내서를 통해 공급기업이 사업기간 중 모델을 완성하는 과정에서 산출되는 AI 솔루션 테스트 결과를 의무적으로 제출하도록 명시

- 사업계획서 상 정량적 목표를 기반해 필요 시 AI 모델의 특성을 대표할 수 있는 지표로 변경하거나 새로 정하여 제출 가능

  *단, 사업계획서 성능목표 하향 적용은 불허하며 지표수정 필요시 반드시 NIPA 담당자에게 사전 연락

- 사업계획서 상에서 정한 성능목표(Metric) 관련 인공지능 모델 기본 정보를 제공하며 AI 모델의 성능목표별 결과와 향상도를 결과서 형태로 제출해야 함

❑ 본 가이드에 첨부한 테스트 결과서 양식을 참조하여 제출

- 솔루션명(버전), 시험주체/일자, 성능목표, 알고리즘, 데이터(훈련/검증/시험), 시험환경/도구, 모델개선 방법/결과, 기타 시험조건/전제 등이 포함되어야 함

- 본 가이드 내용에 부합한 성능목표, 데이터 등 시험환경, 모델개선 주요내용 및 결과를 검토하여 개선사항을 제시

- 테스트 가이드 내용을 충실하게 반영하고 제3자 기업/기관 테스트를 수행/확인하여 필수로 제출

  *** 테스트결과서에는 성능목표, 학습/테스트데이터, 사용 알고리즘, 사용언어, 개발프레임워크 등이 제시되어야 하며, KOLAS 인증 기업의 테스트결과서만 허용**

  *** 제3자를 통해 발급받은 시험결과서나 지정된 컨설팅사를 통해 발급받은 시험결과서는 본 사업 실적증빙용이며, 전담기관이 인정한 <u>인증서 성격이 아님</u>에 유의**

❑ FAQ

ㅇ 모델테스트와 솔루션 성능의 차이가 무엇인지?

; 솔루션은 활용 과정에서 수요처의 요구사항을 충족하면 되는데, 이를 구현하기 위한 요소로서 인공지능 모델의 매트릭 결과가 어떻게 도출되는지를 확인하는 것이 모델테스트입니다.

ㅇ 테스트결과서 내 포함되어야 할 내용은?

; 솔루션명(버전), 시험주체/일자, 성능목표, 알고리즘, 데이터(훈련/검증/시험), 시험환경/도구, 모델개선 방법/결과, 기타 시험조건/전제 등이 포함되어야 합니다.

ㅇ 사업계획서에 기재된 성능 내용과, 테스트 결과서 내용이 달라도 되는지?

; 사업계획서 내 모델 성능과 상이하거나, 매트릭 설정이 잘못된 경우 등에는 수정사업계획서를 제출하여 주관기관 및 NIPA의 승인이 필요할 수 있습니다.

ㅇ 최초 사업계획서의 평가지표는 Rough하게 정의되어 있어, AI 모델의 평가지표가 명확하게 정의되어 있지않는데, 이럴 경우 사업계획서 변경 신청을 해야 하나?

; 평가지표 구체화를 위한 사업계획서 변경은 큰 어려움이 없을 것으로 예상되므로, 변경신청 하시는 것이 바람직합니다.

ㅇ 평가할 매트릭이 테스트 가이드에 나와 있는 매트릭으로는 힘들 것 같은데 어떻게 해야 하나

; AI 모델의 성능을 평가할 수 있는 정량적 매트릭을 새로 정의할 수도 있으나, 모델에 맞는 새로운 매트릭을 정의할 때 매트릭의 선정이유와 배경 설명, 정량적 계산 수식을 반드시 포함해서 언급해야 합니다.

ㅇ 룰 베이스는 테스트 대상이 아니라고 하는데 어떻게 진행해야 하는지?

; 룰 베이스는 인공지능 모델이 아니므로 테스트 대상이 아닙니다.

ㅇ 수요 업체가 운영할 H/W Spec을 모두 만족하면서 테스트를 진행 해야 하는지

; 최종 Solution 테스트가 아닌 Solution을 구성하고 있는 AI 모델 테스트 이므로, 최종 Solution이 동작하는 HW Spec에서 테스트를 진행하지 않아도 됩니다.

ㅇ 다수의 수요처를 대상으로 하고 있는데 테스트 결과서를 각각 제출해야 하는지요?

; 테스트 결과서는 AI모델을 테스트하는 것으로서, 나의 결과서로 발급 가능하나, 결과서 내 과제별 테스트 결과를 각각 제시해야합니다.
특히, 동일한 모델이더라도 과제별 수요처의 현장 데이터로 테스트 진행하기에 테스트 결과는 각각 도출해야합니다.

ㅇ 테스트 방법 및 테스트 가능 업체는 어디인지?

; 테스트는 AI모델이 달성해야 하는 매트릭의 결과도출 과정 및 결과를 확인하는 것으로서 모델의 특성별 차이가 있으므로 테스트 기관과 협의가 필요하며, 테스트 가능업체는 KOLAS 인증 기업의 테스트 결과서만 허용합니다.

ㅇ 수요기업으로부터 아직 데이터를 받지 못했는데, 자사 보유 데이터 학습 결과로 테스트 진행이 가능한지

; 모델에 대한 테스트 결과를 도출하는 것이므로, 보유하고 있는 학습데이터를 활용한 모델에 대해, 학습에 활용되지 않은 테스트 데이터를 활용한 테스트도 가능합니다,
단, 수요처에 납품을 지원하는 바우처 사업 특성상, 테스트 데이터에 수요기업 데이터가 반드시 일부라도 포함되어야 합니다.

ㅇ 테스트를 진행할 때 평가용 데이터는 누가 준비해야 하는지요?

; 학습에 활용되지 않은 평가용 데이터는 의뢰기업(공급기업)에서 준비해야 합니다.

ㅇ 하나의 테스트 결과서에서 AI모델 성적과 다른 성능지표 성적을 함께 받아서 제출해도 되는것인지?

; 테스트 결과서는 모델의 성능 테스트 결과가 기입 되어 있어야 하며, 이외의 성능지표와 구분하여 기술이 되어 있다면 가능합니다.

ㅇ 여러 개 모델이 있을 때 각각을 다 테스트해야 하는지?

; 하나의 솔루션 내에 다수의 모델이 있을 때 모델별로 테스트 결과서를 제출해야 합니다. 다만 대표모델이 있는 경우 대표모델 하나의 테스트 결과를 제출하셔도 됩니다.

ㅇ 꼭 테스트 결과서를 제출해야 하는지?

; AI바우처 사업 참여과제의 테스트 결과서 제출은 필수입니다.

ㅇ 테스트 결과서는 시험성적서로 활용할 수 있는지?

; 제 3자를 통해 발급받은 시험결과서는 본 AI바우처 사업 증빙용이며, 전담기관인 NIPA가 인정한 인증서 성격이 아님에 유의 바랍니다.

2 테스트 결과서 예시

아래 AI바우처 테스트 결과서는 NIPA를 통해 테스트 수행한 결과에 대한 양식 및 예시입니다. 제 3자를 통해 발급 받은 시험결과서도 아래 테스트 결과서를 참고하여 작성하기 바랍니다.

❑ AI바우처 테스트 결과서 요약

회사명 주소 전화	페이지	OOO 시험기관

1. 의 뢰 인
   · 회사(기관)명 : OOOO
   · 주 소 : OOO OOO OOO
   · 계약일자 : 2023년 O월 O일

2. 시험성적서의 용도 : AI바우처 테스트 결과서 제출용

3. 제 품 명 : AI 솔루션의 객체인식 엔터프라이즈 에디션 / 제품 영문명

4. 버 전 : v1.0

5. 시험기간 : 2023. O. O. ~ 2023. O. O.

6. 시험방법 : OOO 모델의 Accuracy, Recall, Precision 매트릭 측정

7. 시험환경 : nd_css_v1 - OS Ubuntu 20,
   ssm_mn_pgs_v1 – Qualcomm Kyro 300 cpu(octa-core),
   RAM 32G, Storage 16G, OS Embedded Linux

8. 시험결과 : 적합 (Accuracy 성능목표 OO을 상회하는 OOOO 달성)
   적합 (Recall/Precision 성능목표 OO를 상회하는 OOOOOO 달성)

비 고 : 1. 이 성적서의 시험결과는 의뢰자에 의해 제공된 시험품에 한하며 용도 이외의 사용을 금합니다.

확 인	시험자 성명 : OOO (서명)	승인자 직책 : 기술책임자 성명 : OOO (서명)

2023년 O월 O일

OOO 시험기관 (인)

❑ 시험 성적서 : 개요, 시험 목적 및 절차

1. 개 요

본 시험결과서는 시험기관 OOO가 OOOO(이하 "시험의뢰기업")의 'AI 솔루션의 객체인식 정확도 v1.0'(이하 "시험대상제품")을 대상으로 시험한 결과를 기술한 문서이다. 본 문서에 명시된 시험결과는 '3. 시험항목 및 방법'과 '4. 시험환경'에서 확인한 결과에 국한된다.

1.1 회사개요

회사(기관)명		대표자명	
사업자등록번호		전화번호	
신청자 성명		신청자 부서/직급	
신청자 이메일		신청자 휴대폰	
회사 주소			

1.2 시험결과서 용도

용도	AI 바우처 지원 사업 제출용
참여 과제	❍ 참여과제명 : ❍ 성능목표 :

2. 시험 목적 및 절차

2.1 시험 목적

2.2 시험 절차

시험 절차는 다음과 같다.

2.3 수행내용 및 시험 기간

시험절차	수행내용	시험기간
시험평가 및 결과서 작성	시험환경 구축, 제품 분석 및 사전 시험평가	3일
	시험항목에 대한 시험 및 평가 수행	
	시험결과서 작성 시험결과서 상호 확인	

❑ 시험 성적서 : 시험항목 및 방법

3. 시험항목 및 방법
3.1 시험항목
시험의뢰기업에서 요청한 시험항목과 시험목표 및 기준은 아래와 같다.

ID	시험항목	시험목표 및 기준
TC1	OOO	<시험목표> 객체의 객체인식 정확도 mAP를 확인함 - 정상동작 기준: mAP가 OO% 이상 ※ AP(Average precision)는 각 물체의 정밀도-재현율(recall-precision) 그래프를 측정하고 그래프의 아래 면적을 계산하는 것을 의미함 ※ mAP는 AP의 평균값을 의미함 ※ 객체 인식 성공은 검출된 물체가 실제 물체와 intersection of unions (IOU)가 OO% 이상이고 객체 종류도 맞혀야 함 ※ 학습데이터: OOO ※ 테스트데이터: OOO ※ 사용 알고리즘: OOO ※. 사용 언어: OOO ※ 개발 프레임워크: OOO <시험기준> o 산정식: X = A / B - A: 전체 시험된 객체의 AP의 합 - B: 전체 시험된 객체의 수 ※ TC1의 시험기준은 시험의뢰기업에서 제공함

ID	시험항목	시험목표 및 기준
TC2	OOO	<시험목표> 객체의 객체인식 정확도 mAP를 확인함 - 정상동작 기준: mAP가 OO% 이상 ※ AP(Average precision)는 각 물체의 정밀도-재현율(recall-precision) 그래프를 측정하고 그래프의 아래 면적을 계산하는 것을 의미함 ※ mAP는 AP의 평균값을 의미함 ※ 객체 인식 성공은 검출된 물체가 실제 물체와 intersection of unions (IOU)가 OO% 이상이고 객체 종류도 맞혀야 함 ※ 학습데이터: OOO ※ 테스트데이터: OOO ※ 사용 알고리즘: OOO ※. 사용 언어: OOO ※ 개발 프레임워크: OOO <시험기준> o 산정식: X = A / B - A: 전체 시험된 객체의 AP의 합 - B: 전체 시험된 객체의 수 ※ TC1의 시험기준은 시험의뢰기업에서 제공함

❑ 시험 성적서 : 시험환경, 시험결과, 시험기록

4. 시험환경

시험환경은 현장 시험환경에 구축하였고, 시험환경구성 및 세부사항은 아래와 같다.

<시험환경 구성>

시험환경 구성도

<세부사항>

세부사항 (장비별 운영체제, CPU, 메모리, 디스크 등)

5. 시험결과

시험 항목별 시험 결과는 아래와 같다. (상세 시험 결과는 "<6. 시험기록>" 참고)

ID	시험항목	평가지표	시험목표 및 기준	결과
TC1	OOO		<시험목표> OOO <시험결과> OOO	적합
TC2	OOO		<시험목표> OOO <시험결과> OOO	적합

6. 시험기록

ID	TC1
상세 시험결과	5가지 객체의 AP의 평균값인 객체인식 정확도 mAP는 OO%로 OO% 이상이므로 정상 동작 확인됨 ※ 측정된 OOO 객체의 AP값을 소수점 셋째자리에서 반올림하여 평균값을 산출함 <세부 측정결과>

No	객체	AP
1		OO.OO%
2		OO.OO%
3		OO.OO%
4		OO.OO%
5		OO.OO%
mAP		OO.OO%

Ⅳ. 인공지능 모델 사례

1 분류 모델

◉ 침입자 및 차량 감지(Intruder and Vehicle Detection)

【 Overview 】

개요	◆ 해당 모델은 이미지에서 사람과 차량을 식별 ◆ 최소 480p 해상도에서 가장 잘 작동하지만 모든 jpg 또는 png 이미지를 입력으로 허용 ◆ 위치, 신뢰도 및 감지 유형 (사람 또는 차량 카테고리)이 포함된 JSON을 출력 ◆ 이 모델은 어둡고 흐릿하고 가려진 이미지에서도 작동하며 실시간 카메라 모니터링과 포렌식 데이터 분석 모두에 효과적임
데이터	◆ 해당 모델은 50 만개 이상의 범죄 및 보안 카메라 이미지에 대한 Actuate의 사내 데이터 세트를 사용하여 훈련 및 테스트 ◆ 1,000개 이상의 보안 카메라 동영상을 포함하여 100,000 개의 고유한 이미지를 학습에 사용하고 겹치지 않는 다른 100,000개를 테스트에 사용 ◆ 150 만 개 이상의 객체 인스턴스가 포함된 오픈 소스 데이터 세트 인 COCO의 전이 학습을 적용
모델	◆ 오픈 소스 기계 학습 플랫폼 인 YOLOv4 1 단계 감지 모델의 Actuate 독점 포크를 사용 ◆ Actuate의 사용자 지정에는 모델의 기본 Darknet 프레임 워크, 네트워크 구조, 확장 및 풀링 매개 변수에 대한 수정이 포함 ◆ 이를 통해 실시간 성능을 유지하면서 복잡하고 품질이 낮은 이미지에서 총기 감지 ◆ 시스템 간 호환성을 유지하기 위해 PyTorch를 사용하여 실행 ◆ 동적 학습률과 확률적 경사 하강 법을 사용하여 훈련
하드웨어	◆ 8x Nvidia Tesla V100 GPU에서 훈련하는 데 50 시간 소요
매트릭	◆ 이미지 당 전체 테스트 데이터 세트에서 96 % 정밀도 및 97 % 재현율을 달성 ◆ 테스트 비디오 샘플에서 사람과 차량을 식별하는 99 % 이상의 리콜을 달성하며, fps가 높을수록 성능이 향상 ◆ 이 모델의 강점에는 저해상도 이미지, 야간 투시경 시나리오, 악천후, 장거리, 관심있는 사람 또는 차량이 빠르게 움직이거나 흐릿하거나 대부분 가려진 경우를 포함하여 어려운 환경에서 사람과 차량을 감지하는 기능이 포함 ◆ 99 % Accuracy - 분류자에 의해 만들어진 정확한 예측의 비율. 정확한 예측 수를 총 예측 수로 나누어 계산 ◆ 97 % F1 Score - 최고 값이 1 인 정밀도 및 재현율의 조화 평균 두 메트릭 간의 균형을 측정

◈ 【분석】 영상 이미지 내 침입자와 차량인식 모델

【 Metric 】

평가지표	Accuracy, F1 Score (사례2 : Recall, Precision, F1 Score)
목표기준	-
시험결과	99% Accuracy, 96% Precision, 97% Recall, 97% F1 Score (사례2 : 0.95 Precision, 0.95 Recall, 0.95 F1 Score)
시험조건	-
평가산식	-

【 Data 】

데이터 원천		50만장 이상의 보안 카메라와 범죄 이미지 (사례2 : ResNet50 으로 학습한 196개 자동차 클래스 5000 x 5000 pixel RGB, JPEG or PNG)
홀드아웃	훈련	중복 없는 100,000장 학습 이미지 (사례2 : ResNet으로 학습한 196개 자동차 클래스 16,185장 이미지 중 절반인 8,144장을 훈련 데이터로 사용)
	검증	-
	시험	중복 없는 100,000장 시험 이미지(1,000개 카메라 영상 포함) (사례2 : ResNet으로 학습한 196개 자동차 클래스 16,185장 이미지 중 8,041장을 시험 데이터로 사용)
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		-

【 Model 】

알고리즘	YOLOv4
참조모델	COCO(99%+ Recall, 98% precision 성능수준의 사람과 차량영상 인식 모델)
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	PyTorch
AutoML	-
하드웨어	8x Nvidia Tesla V100 GPUs 50시간 학습

◉ 피부암 검진 (Skin Cancer Screening)

【 Overview 】

개요	◆ Skin Cancer Screening Network (SkinCancerScreenNet)는 jpg 유형의 피부 병변 피부 경 검사 이미지를 입력으로 받아들이고 병변이 양성이거나 악성 일 가능성을 출력으로 예측하는 심층 컨볼루션 신경망 모델 ◆ 피부 dermoscopy 이미지에 사용할 수 있으며 단일 이미지 또는 이미지 세트에 사용 가능
데이터	◆ 해당 모델은 23,000 개가 넘는 피부 병변 이미지로 구성된 오픈 액세스 데이터 세트 인 ISIC 데이터 세트를 사용하여 훈련 ◆ 학습은 ISIC 데이터 세트의 21,659 이미지 하위 집합에서 학습 ◆ 검증은 악성 흑색 종 이미지 221 개, 양성 모반 이미지 221 개로 ISIC 데이터 세트의 442 개 이미지 하위 집합에서 검증
모델	◆ SkinCancerScreenNet은 인간-기계 협업 설계 전략을 사용하여 개발 ◆ 인간 중심의 원칙적 네트워크 설계 프로토 타이핑과 기계 중심의 설계 탐색이 결합되어 피부암 탐지를 위해 특별히 맞춤화 된 네트워크 아키텍처를 생성 ◆ SkinCancerScreenNet은 여전히 높은 성능 수준을 달성하면서 520K 매개 변수로 구성되며 더 높은 민감도 수준으로 조정 ◆ Tensorflow에서 구현
하드웨어	◆ 추론을 수행할 때 GPU를 사용하는 것을 추천
매트릭	◆ 테스트 데이터 세트에서 SkinCancerScreenNet은 민감도 92 %, 특이도 77 %를 달성 ◆ PPV (Positive-Predictive-Value) - 79.9 % (PPV 정밀도 점수가 높을수록 다른 클래스에 대해 모델에서 예측한 대부분의 레이블이 정확함을 나타냄) ◆ Sensitivity – 91.9 % (더 높은 재현율 점수는 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측한다는 것을 나타냄)

◉ 물체 위치 추적 (Object Position Tracking)

【 Overview 】

개요	◆ 해당 모델은 표준을 준수하는 측지 메타 데이터를 포함하는 모든 비디오에서 객체를 측지적으로 추적 ◆ 모든 도메인의 개체를 추적할 수 있도록 대규모 데이터 세트에 대해 종단 간 학습된 Siamese 지역 제안 네트워크 (Siamese-RPN)를 사용 ◆ MISB ST 0601 표준에 따라 패키징 된 MPEG 및 MP4 비디오 파일을 입력으로 사용하고 JSON 형식의 트랙 세트와 zip 아카이브 형식의 ESRI를 모두 생성하여 비디오의 각 프레임에서 추적된 개체의 위도 및 경도 좌표를 출력 ◆ 연속된 이미지 또는 비디오 프레임에서 사람, 차량과 같은 움직이는 물체를 추적하는 데 사용할 수 있음
데이터	◆ 로그 공간에서 학습하는 동안 0.01에서 0.000001로 감소한 학습률로 확률적 경사 하강 법을 사용하여 50 epoch 동안 Youtube-BB 데이터 세트에서 학습 ◆ Youtube-BB 데이터 세트에는 30프레임마다 한 번씩 주석이 달린 100,000개의 동영상이 포함 ◆ VOT2015, VOT2016 및 VOT2017 데이터 세트(60개) 비디오 및 포함하는 각 OTB2015(100개) 동영상을 포함
모델	◆ 해당모델은 AlexNet 및 ResNet 의 두 가지 다른 유형의 기능 추출기와 함께 작동하도록 훈련 ◆ 피쳐 추출기 뒤에는 객체 추적을 수행하는 Siamese 지역 제안 네트워크가 연결됨 ◆ RPN (Region Proposal Network)은 Faster R-CNN 설계에서 처음 제안 ◆ 물체 감지 모델용 RPN은 전경-배경 기능을 분석하고 경계 상자 회귀를 수행하여 정확한 제안 영역을 추출 ◆ Siamese 네트워크는 원래 패치를 다른 공간으로 암시적으로 인코딩 한 다음 특정 텐서와 융합하여 단일 출력을 생성하는 두 개의 분기가 있는 네트워크 ◆ 이 아키텍처는 일반적으로 대조 작업을 위해 공통 임베디드 공간에서 두 개의 네트워크 분기에서 생성된 두 세트의 기능을 비교하는 데 사용 ◆ PyTorch에서 구현
매트릭	◆ 57 % Average Accuracy 평균 정확도 – 다양한 클래스의 정확도 평균 ◆ 35 % 예상 평균 오버랩 (EAO) – 추적기가 주어진 데이터 세트와 시각적 속성이 동일한 대규모 단기 시퀀스 모음에서 달성할 것으로 예상되는 평균 오버랩 추정치 ◆ 97 % Average Robustness 평균 견고성 – 모델이 연속적인 프레임 시퀀스에서 평균적으로 특정 개체를 얼마나 견고하게 추적하는지 측정

◉ 다국어 개념 추출 (Multilingual Concept Extraction (F1 Score, Precision, Recall))

【 Overview 】

개요	◆ Blackbird.AI의 Multilingual Concept Extraction 모델은 엔티티 (사람, 위치, 조직, 장소, 시간), 컨텍스트 동인 (이념, 사망 원인, 형사 고발, 종교), 핵심 문구, 소셜 태그 및 영어 텍스트의 URL을 감지하고 분류 ◆ 아랍어 및 스페인어에 대한 베타 지원 포함. ◆ 출력은 카테고리별로 레이블이 지정된 추출된 텍스트 ◆ 이 모델은 소셜 미디어, 뉴스 미디어 또는 웹 데이터의 디지털 내러티브에 대한 자연어 이해에 사용할 수 있음
데이터	◆ 참여 당사자 : – 사람 (예 : Anthony Fauci, Donald Trump, Neera Tanden) – 조직 (예 : FDA, New York Times, PETA) - 직함 (예 : 사장, 배우, 농부) – 사용자 멘션 (예 : @nytimes, @BorisJohnson) ◆ 리드 카테고리 : – 주요 문구 (예 : 여러 주 선거결과, 투표용지 우편, 빌게이트 백신, 현대 코비드 백신 연구) – HASHTAG 예 : #thehandmaidstale, #vaccines, #election – URL 예 : http://www.blackbird.ai ◆ 장소 : – 위치 (예 : 위스콘신, 중국, 브라질, 미국) – 국적 (예 : 미국, 인도, 중국) ◆ 문맥 동인 : – 이데올로기 (예 : 자본주의, 민주당 원, 공화당 원, 사회주의, 우익) – 종교 (예 : 힌두교, 무슬림, 독립) / 죽음의 원인 (예 : 전쟁, 질병, 암) – 형사 고발 (예 : 강탈, 뇌물, 강간) / MISC (예 : DNA, 1100 만) 미국인 ◆ 임시 : – 설정 (예 : 매일, 매년) / TIME (예 : 밤, 아침) / DATE (예 : 2019, 작년, 지금) – DURATION (예 : 년, 지난 2 년)) ◆ 대규모 (수백만 개의 문서) 및 다양한 Twitter 데이터 세트에 대한 전체 및 반 감독의 조합과 다양한 주제를 다루는 평판 좋은 뉴스 콘텐츠를 사용하여 학습 ◆ 모델 검증은 개념 식별에 대한 모델의 성능을 정량화하기 위해 16K 소셜 미디어 및 뉴스 문서를 포함하는 훈련 데이터의 테스트 분할에서 수행
모델	◆ 이 모델은 대규모 (수백만 개의 문서) 및 다양한 Twitter 데이터 세트와 다양한 주제모델의 강점은 짧은 형식 (소셜) 및 긴 형식 (뉴스 기사) 텍스트 모두에서 잘 작동하고 지연 시간이 매우 짧고 스트리밍 피드 처리에 적합 ◆ 모델의 약점은 본질적으로 다국어이지만 추가 교육 없이는 비 영어 언어에서는 잘 작동하지 않는다는 것 ◆ 고객 요청에 따라 어떤 언어로든 쉽게 적용하고 개선 가능 ◆ 입력 : input.txt (Max 1MB) / 출력 : results.json (Max 1MB)
매트릭	◆ 89.6 % F1 Score - 최고값이 1 인 정밀도와 재현율의 조화 평균(두 메트릭 간의 균형을 측정) ◆ 89.7 % Precision(정밀도) - 정밀도 점수가 높을수록 서로 다른 클래스에 대해 모델에서 예측 한 대부분의 레이블이 정확함 ◆ 89.6 % Recall(재현율) - 재현율 점수가 높을수록 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측

◉ 비디오 편집 (Video Redaction (Expected Average Overlap (EOA), Robustness))

【 Overview 】

개요	◆ Modzy의 모델을 이용했으며, 주어진 비디오 내에서 사용자 지정 개체를 수정 ◆ 이 기능은 비디오에 기록된 엔터티의 개인정보를 보호하고 민감한 콘텐츠를 검열하는 데 유용 ◆ 먼저 관심있는 엔티티를 식별하고 블랙 박스로 수정한 다음 비디오 전체에서 추적하여 알 수 없도록 함
데이터	◆ 객체 추적 모델은 VOT2015, VOT2016 및 VOT2017 데이터 세트에서 테스트되었으며 각각 60 개의 비디오가 포함되어 있음 ◆ 또한 100 개의 비디오가 포함된 OTB2015 데이터 세트를 사용하여 검증

모델	◆ 객체 추적 모델은 로그 공간에서 학습하는 동안 0.01에서 0.000001로 감소한 학습률로 확률 적 경사 하강 법을 사용하여 50 epoch 동안 Youtube-BB 데이터 세트에서 학습
	◆ 이 모델의 수정 부분은 결정적이므로 교육이 필요하지 않음
	◆ 이 모델은 두 단계로 작동. 첫째, 첫 번째 프레임의 사용자 지정 개체가 비디오 전체에서 추적. 객체 추적 모델은 AlexNet 및 ResNet 의 두 가지 기능 추출기 중 하나를 사용. 다음 기능 추출기 뒤에는 Siamese-RPN (Siamese Region Proposal network)이 존재함
	◆ 이 네트워크는 객체를 추적하고 프레임 당 경계 상자를 반환. 그런 다음 해당 경계 상자 내의 모든 픽셀을 검은 색으로 설정하여 이러한 개체를 수정.
	◆ 입력 : input.mpg or input.mp4 (Max 1GB) / config.json (Max 1MB)
	◆ 입력 비디오의 해상도는 4096 × 2160보다 높을 수 없으며 최대로 처음 10,000 개 프레임을 읽음. "config.json"파일은 비디오 전체에서 추적하고 수정할 객체의 첫 번째 프레임에 경계 상자를 포함해야 하며 형식은 다음과 같음
	`{`
	`"boundingBox": [[x1, y1, width3, height1], [x2, y2, width3, height2]]`
	`}`
	◆ 모든 경계 상자 값은 픽셀 수. "x1"및 "y1"값은 왼쪽 상단 경계 상자 모서리에 해당. "x1"은 프레임 왼쪽부터의 픽셀 수이고 "y1"은 프레임 위쪽에서 아래쪽의 픽셀 수.
	◆ 출력 : output.mpg (Max 1GB)

매트릭	◆ 57 % 평균 정확도 – 다양한 클래스의 정확도 평균 ◆ 35 % EAO (예상 평균 겹침) – 예상 평균 겹침, 예상 경계 상자가 프레임 창에서 관심 대상과 겹치는 평균 시간 ◆ 97 % 견고성 – 종합적으로 생성된 적대적 테스트 데이터 세트에서 분류자가 만든 올바른 예측의 비율. 이 메트릭은 적대적 공격에 대한 모델의 탄력성을 측정.

◉ 보행자 차량 활동 감지 (Pedestrian Vehicle Activity Detection (Partial Area Under (DET) Curve, Probability of Missed Detections, Time Based Probability of Missed Detections))

【 Overview 】

개요	◆ Modzy의 모델을 이용했으며, 고정 카메라로 캡처 한 비디오에서 사람과 차량 활동을 감지, 추적 및 분류 ◆ 모듈식 파이프 라인으로 설계 ◆ 공개적으로 사용 가능한 데이터 세트. MP4 비디오 파일을 입력으로 받아 감지된 사람과 차량의 경계 상자와 트랙릿 (트랙 조각 뒤에 움직이는 물체), 활동 레이블 및 해당 신뢰 점수가 포함 된 JSON 파일을 반환 ◆ 활동 유형은 사람 만 (진입, 출구 등), 차량 만 (U 턴, 우회전 / 좌회전 등), 사람-차량 상호 작용 (사람이 차량 문을 열고 사람이 열림)의 세 가지 버킷으로 그룹화
데이터	◆ 이 모델은 VIRAT 및 MEVA (Multiview Extended Video with Activities) 공개적으로 사용 가능한 데이터 세트 에서 학습 및 평가 ◆ VIRAT 데이터 세트에는 11 개의 서로 다른 야외 장면에서 12 가지 이벤트 유형에 대한 주석이 포함된 약 8.5 시간의 HD 비디오 데이터가 포함 ◆ MEVA 데이터 세트에는 UAV 비디오, 카메라 모델 및 12.5 시간의 주석 데이터 하위 집합과 같은 추가 리소스와 함께 250 시간 이상의 지상 카메라 비디오가 포함
모델	◆ 해당 모델은 모듈 식으로 학습되었음. 즉, 파이프 라인의 각 단계는 개별적으로 학습된 모델로 구성되며 각 모델의 출력은 다음으로 파이프됨. ◆ 파이프 라인의 첫 번째 단계인 객체 감지 및 추적은 Mask RCNN 아키텍처를 백본으로 사용 ◆ 다음 단계인 제안 생성은 첫 번째 단계에서 얻은 사람과 차량 궤적을 분석하여 위에서 설명한 세 가지 주요 활동 버킷에 속하는 후보를 공간 및 시간적으로 지역화합니다. ◆ 다음 제안은 최종 단계, 기능 추출 및 활동 분류로 전달 ◆ 특징 추출 단계는I3D 아키텍처 및 양방향 LSTM 이 시간 활동 분류에 사용되며, 두 모델 모두 VIRAT 및 MEVA 데이터 세트에서 미세 조정되었음. ◆ 입력 : input.mp4 (Max 200MB) / 출력 : results.json (Max 5MB) ◆ 출력 JSON에는 감지된 각 활동에 대한 항목이 포함. 나열된 각 활동에는 클래스 레이블 ("활동"), 신뢰도 점수 ("presenceConf") 및 활동에 관련된 개체 목록 ("개체")이 포함하며, 다음 활동들을 감지 Closing (P, V) or (P) / Closing_trunk (P, V) / Entering (P, V) or (P) / Exiting (P, V) or (P) Loading (P, V) / Open_Trunk (P, V) / Opening (P, V) or (P) / Transport_HeavyCarry (P, V) Unloading (P, V) / Vehicle_turning_left (V) / Vehicle_turning_right (V) / Vehicle_u_turn (V) Pull (P) / Riding (P) / Talking (P) / activity_carrying (P) specialized_talking_phone (P) / specialized_texting_phone (P) - "(P)"는 사람 만, "(V)"는 차량 만, "(P, V)"는 사람과 차량의 상호 작용을 의미 - 활동에 관련된 각 개체에는 'Person'또는 'Vehicle'을 포함하는 'objectType'이라는 속성과 관련 프레임 번호로 인덱싱 된 경계 상자 집합이 있음 - 경계 상자 정보는 키 이름이 'localization'인 개체의 속성이며, 각 경계 상자에는 상자의 왼쪽 상단 "x"및 "y"좌표와 함께 상자 너비 "w"및 높이 "h"가 픽셀 단위로 나열
매트릭	◆ 48.4 % DET (Partial Area Under) 곡선 – 부분 Area Under DET 곡선은 주어진 신뢰 구간에서 잘못된 경보 비율과 누락된 탐지 확률 간의 관계를 정량화 ◆ 79.8 % 누락된 감지 확률 – 특정 비율의 잘못된 경보 값을 발생시키는 존재 신뢰도 임계 값에서 누락된 감지 수에 대한 실제 활동 인스턴스 수의 비율 ◆ 누락된 감지의 39.2 % 시간 기반 확률 – 특정 시간 기반 잘못된 경보 값을 생성하는 존재 신뢰도 임계 값에서 누락된 감지 수에 대한 실제 활동 인스턴스 수의 비율 (실제 비 활동 인스턴스 시간의 비율 시스템에서 잘못 감지된 값의 기간.

◉ 물체 위치 추적 (Object Position Tracking (Average Accuracy, EAO, Average Robustness))

【 Overview 】

개요	◆ 해당 모델은 Modzy의 모델을 이용했으며, 표준을 준수하는 측지 메타 데이터를 포함하는 모든 비디오에서 객체를 측 지적으로 추적할 수 있음 ◆ 모든 도메인의 개체를 추적할 수 있도록 대규모 데이터 세트에 대해 종단 간 학습된 Siamese 지역 제안 네트워크 (Siamese-RPN)를 사용 ◆ MISB ST 0601 표준에 따라 패키징 된 MPEG 및 MP4 비디오 파일을 수용하고 JSON 형식의 트랙 세트와 zip 아카이브 형식의 ESRI를 모두 생성하여 비디오의 각 프레임에서 추적 된 개체의 위도 및 경도 좌표를 출력 ◆ 연속된 이미지 또는 비디오 프레임에서 사람, 차량과 같은 움직이는 물체를 추적하는 데 사용할 수 있음
데이터	◆ 학습에 사용된 데이터에는 Youtube-BB 데이터 세트에는 30 프레임마다 한 번씩 주석이 달린 100,000 개의 동영상이 포함 ◆ 테스트는 VOT2015 , VOT2016 및 VOT2017 데이터 세트 (60 개) 비디오 및 포함하는 각 OTB2015 (100 개) 동영상을 가지고 실시
모델	◆ 이 모델은 AlexNet 및 ResNet 의 두 가지 다른 유형의 기능 추출기와 함께 작동하도록 훈련 ◆ 피쳐 추출기 뒤에는 객체 추적을 수행하는 Siamese 지역 제안 네트워크가 연결됨 ◆ RPN (Region Proposal Network)은 Faster R-CNN 설계에서 처음 제안되었음 ◆ 물체 감지 모델용 RPN은 전경-배경 기능을 분석하고 경계 상자 회귀를 수행하여 정확한 제안 영역을 추출할 수 있음 ◆ Siamese 네트워크는 원래 패치를 다른 공간으로 암시적으로 인코딩 한 다음 특정 텐서와 융합하여 단일 출력을 생성하는 두 개의 분기가 있는 네트워크이며, 일반적으로 대조 작업을 위해 공통 임베디드 공간에서 두 개의 네트워크 분기에서 생성된 두 세트의 기능을 비교하는 데 사용 ◆ PyTorch에서 구현 ◆ 입력 : input.mpg or input.mp4 (Max 1GB) / config.json (Max 1MB) ◆ 출력 : results.json (Max 2MB)
매트릭	◆ 57 % 평균 정확도 – 다양한 클래스의 정확도 평균 ◆ 35 % 예상 평균 오버랩 (EAO) – 추적기가 주어진 데이터 세트와 시각적 속성이 동일한 대규모 단기 시퀀스 모음에서 달성할 것으로 예상되는 평균 오버랩 추정치 ◆ 97 % 평균 견고성 – 모델이 연속적인 프레임 시퀀스에서 평균적으로 특정 개체를 얼마나 견고하게 추적하는지 측정

◉ 그래프 임베딩 (Graph Embeddings (Macro-F1 score))

【 Overview 】

개요	◆ Modzy의 모델을 사용한 해당 모델은 비슷한 관심사를 공유하는 사람을 찾거나 단백질 쌍 간의 생물학적 상호 작용을 찾는 것과 같이 엔티티 간의 가능한 관계를 탐색하는 데 사용 ◆ 그래프는 관계형 엔터티를 설명하는데 특히 유용하며 그래프 임베딩은 그래프의 속성을 유지하면서 그래프의 구조를 AI 모델에서 소화 가능한 형식으로 변환하는 데 사용되는 접근 방식 ◆ 그래프 구조는 규모, 특이성 및 주제 측면에서 매우 다양하므로 매우 어려운 작업임
데이터	◆ BlogCatalog 데이터 세트, Facebook 데이터 세트
모델	◆ 먼저 주어진 입력 텍스트 파일의 에지 데이터에서 NetworkX 그래프를 생성하여 그래프 임베딩을 생성 ◆ 그 다음 node2vec 알고리즘의 매개 변수에 따라 그래프의 각 노드에서 임의의 걷기를 생성 ◆ 이러한 매개 변수는 임베딩 공간의 크기, 각 노드에서 시작하는 걷기 수, 각 걷기의 길이 및 걷기가 이전에 방문한 노드 또는 새 노드로 진행될 확률을 나타냄 ◆ 이러한 매개 변수는 임의 걷기가 이전에 방문한 노드가 아닌 새 노드를 방문할 가능성을 약 4배 더 높임. 즉, 모델은 너비 우선 검색보다 깊이 우선 검색을 더 많이 수행하며, 얕은 신경망, Skip-Gram 네트워크, 노드 임베딩을 생성하는 데 사용 ◆ 각 노드 쌍의 임베딩은 Hadamard 연산자를 통해 전달되어 해당 노드를 엔드 포인트로 사용하는 에지 임베딩을 생성 ◆ 최종 출력은 각 노드의 128 차원 임베딩과 그래프 노드 사이의 각 에지와 비에지의 128 차원 임베딩임 ◆ 해당 모델의 훈련은 입력 그래프에 대해 생성된 임의 걷기에서 새로운 Skip-Gram 네트워크를 훈련 ◆ 스킵 그램 네트워크는 크기가 N 인 입력 및 출력 계층이 있는 신경망으로, 크기가 NxD 인 숨겨진 계층이 하나 있으며, N은 노드 수이고 D는 임베딩 공간의 차원 수 ◆ 네트워크는 각 노드가 입력 단어의 컨텍스트 창에 나타날 확률을 예측 ◆ 네트워크는 확률적 경사 하강 법을 사용하여 5epoch 동안 훈련 - epoch : 학습 시 모든 학습데이터를 사용하여 학습을 완료한 수행 횟수 ◆ 훈련 후에는 출력 계층이 무시되고 숨겨진 계층의 가중치가 그래프 노드의 임베딩으로 사용 ◆ 임베딩으로 인해 임베딩 공간에서 유사한 노드와 유사한 에지가 서로 가까이 있는 것을 확인하여 여러 네트워크에서 경험적으로 검증되었음 ◆ 입력 : edge.txt (Max 10MB) - 입력 파일의 첫 번째 줄에는 "그래프"또는 "digraph"라는 단어가 포함되어야 하며 각 후속 줄에는 선택적 가장자리 가중치와 함께 가장자리의 끝점 인 노드 이름이 포함되어야 함 - 예 : graph 1 2 1 1 2 1 2 0 2 1 1 3 4 ◆ 출력 : results.json (Max 1000GB) - 출력 파일 "results.json"에는 노드 및 에지 임베딩 벡터가 포함 - 최상위 키는 "노드 임베딩"및 "엣지 임베딩" - "Node Embeddings"키에 해당하는 값은 키가 노드 이름이고 값이 해당 임베딩 벡터인 객체 - "Edge Embeddings"키에 해당하는 값은 키가 해당 노드 이름으로 표시되는 가장자리이고 값이 해당 임베딩 벡터 인 객체
매트릭	◆ 96.8 % AUC (Area Under Curve)-AUC (Area Under Curve)는 모델이 무작위 음성 샘플의 순위보다 높은 무작위 양성 예제의 순위를 매길 확률로 해석 ◆ 25.8 % 매크로 F1 점수 – Macro-F1 점수는 각 레이블에 대한 F1 점수의 산술 평균으로 계산됩니다. 다중 레이블 분류에 사용되는 기본 메트릭 ◆ 이 모델은 BlogCatalog 데이터 세트에서 Macro-F1 점수 0.2581과 Facebook 데이터 세트에서 AUC (Area Under Curve) 점수 0.9680을 달성

◉ 오디오 지문 (Audio Fingerprinting (Top 1/5 Accuracy))

【 Overview 】

개요	◆ Modzy의 모델을 이용하였으며, 음향 지문은 오디오 신호에서 생성된 디지털 요약 ◆ 오디오 파일이 주어지면 고유한 사운드 패턴을 감지하여 대표적인 디지털 서명을 생성 ◆ 해당 디지털 임베딩은 음악 조각에서 노래 이름 식별, 액세스 제어를 위한 음성 식별, 비디오 배경에서 실행중인 장비 감지 등 다양한 방식으로 사용될 수 있음
데이터	◆ 해당 모델은 자동 음성 인식 시스템 및 기타 오디오 특정 딥 러닝 시스템의 개발 및 평가를 위해 음성 데이터를 제공하도록 설계된 음성 코퍼스 인 DARPA TIMIT 데이터 세트에서 학습 ◆ TIMIT는 미국의 8 개 주요 방언 지역에서 온 630 명의 화자 각각이 말한 총 6,300 개의 문장, 10 개의 문장으로 구성 ◆ 해당 모델은 462 명의 스피커가 포함된 TIMIT의 하위 집합에서 360 epoch에 대해 훈련되었음 ◆ 검증시 해당 모델은 15명의 고유 스피커가 생성한 10개의 음성 샘플과 12개의 고유한 환경 소리에 대한 40개의 사운드 샘플로 구성된 혼합 데이터 세트에 대한 클러스터링 기반 접근 방식을 사용하여 검증
모델	◆ 해당 모델은 SincNet 아키텍처를 기반으로 오디오 파일의 디지털 서명, 즉 오디오 지문을 생성 ◆ SincNet은 첫 번째 컨벌루션 계층에서 특정 필터 요소를 학습하는 데 중점을 두는 컨볼루션 신경망 (CNN) ◆ 이 네트워크는 매개 변수화 된 sinc 함수를 사용하여 오디오 신호의 낮은 및 높은 차단 주파수만 학습하므로 표준 CNN보다 더 효율적인 학습 방법을 제공 ◆ SincNet은 원래 스피커 클래스 확률을 반환하도록 설계되었지만 해당 모델은 SoftMax 출력 계층을 제거하여 오디오 파일의 압축된 지문을 생성 ◆ 입력 : input.wav, ogg, flac (Max 1MB) / 출력 : results. json ◆ - 출력 JSON 파일은 주어진 오디오 입력에 대해 2,048차원 벡터 임베딩을 보유
매트릭	◆ 94.6 % 상위 1개 정확도 – 총 입력 샘플 수에 대한 상위 1개 예측 클래스의 올바른 예측 수의 비율 ◆ 97.3 % 상위 5개 정확도 – 분류기에서 만든 상위 5개 예측의 비율 ◆ 이 비지도 모델의 성능을 평가하기 위해 생성된 오디오 지문을 화자 분류를 위한 클러스터링 알고리즘으로 테스트 ◆ 해당 모델은 TIMIT 코퍼스 테스트 세트에서 Top 1 정확도 0.9458과 Top 5 정확도 0.9725를 달성

◉ 음성 언어 식별 (Spoken Language Identification (F1 Score, Precision, Recall))

【 Overview 】

개요	◆ 오픈 소스 모델로 해당 모델은 오디오 파일에서 사용되는 언어를 식별 ◆ 받아들일 수 있는 언어는 영어, 독일어, 프랑스어, 스페인어, 중국어 및 러시아어 ◆ WAV 파일을 입력으로 받으며, 각 언어의 확률이 포함된 JSON 파일을 반환 ◆ 해당모델은 고객 또는 구성 서비스 호출의 언어를 결정하거나 음성 메시지의 언어를 감지하여 텍스트로 정확하게 변환하거나 번역하는 데 사용할 수 있음
데이터	◆ YouTube News Dataset 이라는 맞춤 데이터 세트에 대해 교육을 받음 ◆ 이 데이터 세트는 공식 BBC News5 YouTube 채널과 같은 YouTube 채널에서 수집 ◆ 얻은 오디오 데이터에는 원하는 속성이 많이 있음 ◆ 오디오 녹음의 품질은 매우 높으며 온라인에서 수백 시간을 사용할 수 있음 ◆ 뉴스 프로그램에는 종종 게스트 또는 원격 통신원이 등장하여 서로 다른 스피커가 잘 섞여 있음 ◆ 실제 상황에서 기대할 수 있는 소음, 즉 음악 소리, 비 음성 등을 특징으로 가지고 있음 ◆ 전체적으로 이 데이터 세트에 대해 1,508시간 분량의 오디오 데이터를 수집하여, 70%는 훈련에 사용 ◆ 해당 모델은 YouTube 뉴스 데이터 세트의 10%에서 테스트되었으며 나머지 10%에서 검증
모델	◆ 해당 모델 은 Convolutional Neural Network 및 Recurrent Neural Network의 조합을 사용하여 시각 기능과 시간 기반 기능을 활용 ◆ 오디오는 먼저 스펙트로 그램으로 변환된 다음 컨볼루션 특징 추출기로 공급 ◆ 이 추출기는 입력 이미지를 여러 단계로 컨볼루션하고 기능 맵을 생성한 다음 x 축을 따라 슬라이스하고 각 슬라이스를 후속 BLSTM 네트워크 의 시간 단계로 사용 ◆ 컨볼루션 특징 추출기의 디자인은 잘 알려진 VGG가 기반 ◆ 네트워크에는 5개의 컨볼루션 계층이 있으며 각 계층은 Relu 활성화, 배치 정규화 및 최대 풀링 계층이 연결됨 ◆ BLSTM은 두 개의 단일 LSTM으로 구성되어 있으며 연결되어 분류기 역할을 하는 완전 연결 계층으로 공급 ◆ 입력 : input.wav (Max 100MB) / 출력 : results. json (Max 1MB)
매트릭	◆ 91 % F1 점수 – F1 점수는 정밀도와 재현율의 조화 평균, 최고값은 1, 두 메트릭 간의 균형을 측정 ◆ 91 % 정밀도 – 정밀도 점수가 높을수록 서로 다른 클래스에 대해 모델에서 예측 한 대부분의 레이블이 정확함을 나타냄 ◆ 91 % 재현율 – 재현율 점수가 높을수록 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측함을 나타냄 ◆ 이 모델은 분류에서 일반적으로 사용하는 정밀도, 재현율 및 F1 점수를 메트릭으로 사용. ◆ 해당 모델에서 사용된 메트릭들은 결과의 라벨을 잘못 지정하지 않고, 라벨을 지정해야 하는 데이터를 놓치지 않는 모델의 능력, 모델 성공에 대한 전반적인 감각을 제공하는 이러한 값의 조화 평균을 나타냄 ◆ 영어가 88 % F1 점수에서 가장 나쁘고 중국어가 96 % F1 점수에서 최고를 기록하는 등 언어에 따라 약간의 차이가 있었음

◉ 감정 분석 (Sentiment Analysis (F1 Score, Precision, Recall, Ground Truth Correlation))

【 Overview 】

개요	◆ 오픈 소스 모델로 텍스트를 분석하여 텍스트에 표현된 감정을 찾음 ◆ 텍스트 문장을 입력으로 받으며 입력을 통해 극성에 대한 감정 점수, 즉 문장이 얼마나 긍정적인지 부정적인지, 문장의 감정의 강도를 생성 ◆ 이 모델은 텍스트를 쓰는 사람의 감정을 이해하는 것이 중요한 많은 상황에 적용될 수 있음 ◆ 조직이 적절하게 대응할 수 있도록 고객, 유권자, 공급 업체 또는 다른 사람들이 만족하는지 여부를 결정하는 데 사용할 수 있음
데이터	◆ 모델에 사용된 어휘는 이전 어휘를 검토하고 이모티콘, 감정 관련 약어 (예 : LOL) 및 속어 (예 : 'meh')를 포함한 어휘 기능을 추가하여 구축 ◆ 베이더 모델 , 즉 A)원시 감정 강도 평가로 사전에 선별되고 적절하게 훈련된 20명의 평가자의 평균 감정 등급상관 관계를 측정하여 평가뿐만 아니라, B) 멀티 클래스 (긍정적, 부정, 중립) 정밀도, 재현율 및 F1 점수의 분류 메트릭. 검증 세트에는 소셜 미디어 (4,000 개의 트윗), 10,605 개의 영화 리뷰, 3,078 개의 제품 리뷰 및 5,190 개의 의견 뉴스 기사가 포함
모델	◆ 이 모델은 훈련 데이터를 사용하지 않지만 일반화 가능하고 원자가 기반의 사람이 선별한 감정 어휘집으로 구성 ◆ 어휘집은 소셜 미디어에 표현된 감정의 극성과 강도 모두에 민감하지만 다른 텍스트 소스에 적용 할 수 있음 ◆ 규칙 기반은 감정 강도를 평가하기 위해 텍스트의 문법적 및 구문적 측면의 일반적인 사용을 캡처 ◆ 이 과정에서 9,000개 이상의 어휘 기능 후보가 생성되었으며, 군중의 지혜 접근 방식을 사용하여 각 컨텍스트 프리 후보 기능의 감정 가치 (강도)에 대한 유효한 포인트 추정치를 획득하여 약 7,500개의 최종 기능을 생성 ◆ 어휘 기능은 구문, 대문자 및 구두점을 기반으로 하는 휴리스틱과 결합되었으며, 각각은 감정 강도를 직접 나타냄 ◆ 입력 : input.txt (Max 1MB) / 출력 : results. json (Max 1MB)
매트릭	◆ 96 % F1 점수 – F1 점수는 정밀도와 재현율의 조화 평균이며 최고값은 1. 두 메트릭 간의 균형을 측정 ◆ 88 % Ground Truth Correlation – 계산된 원시 감정 강도 등급과 인간 개인의 평균 감정 등급 간의 상관 관계 ◆ 99 % 정밀도 – 정밀도 점수가 높을수록 서로 다른 클래스에 대해 모델에서 예측한 대부분의 레이블이 정확함을 나타냄. ◆ 94 % 재현율 – 재현율 점수가 높을수록 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측함을 나타냄. ◆ 해당 모델은 소셜 미디어에서 잘 작동하며, Ground Truth (인간 리뷰어의 판단)와의 상관 관계는 0.88, 정밀도 0.99, 재현율 0.94, F1 점수 0.96이 나왔음. ◆ 다른 유형의 데이터의 경우 이러한 메트릭은 낮은 결과를 나타냈지만 다른 어휘 기반 도구보다 높았음.

◉ 코로나 판독 (COVID-NET (Positive-Predictive-Value (PPV)))

【 Overview 】

개요	◆ Darwin AI의 모델을 이용한 COVID-Net 신경망은 JPEG 및 PNG 유형의 흉부 X- 레이를 수신하고 이미지를 분석하여 환자가 COVID19 폐렴, 일반 폐렴 또는 건강에 감염될 가능성을 백분율로 반환 ◆ 해당 모델은 전두엽 X- 레이 스캔에만 사용할 수 있으며 단일 이미지 또는 이미지 세트에 사용할 수 있음
데이터	◆ 모델은 5개의 오픈 액세스 데이터 저장소의 조합으로 생성된 14000개 이상의 CXR 이미지로 구성된 오픈 액세스 벤치마크 데이터 세트인 COVIDx를 사용하여 학습 ◆ COVIDx는 우리가 아는 한 가장 많은 공개된 COVID-19 양성 사례를 보유 ◆ 이 모델은 473개의 COVID-19 양성 이미지, 5459개의 Pneumonic (Non-COVID-19) 이미지 및 7966개의 Non-Pneumonic 이미지로 구성된 COVIDx 데이터 세트의 13898 이미지 하위 집합에서 학습 ◆ 검증은 100개의 COVID-19 양성 이미지, 100개의 Pneumonic (Non-COVID-19) 이미지 및 100개의 Non-Pneumonic 이미지로 구성된 COVIDx 데이터 세트의 300개 이미지 하위 집합에서 검증 ◆ COVID-19 CXR 데이터 제한으로 인해 유효성 검사 및 테스트 데이터 세트가 동일하고 탐지 클래스 간의 분할이 균등하지 않음
모델	◆ COVID-Net 설계는 인간-기계 협업 설계 전략을 사용하여 개발되었으며, 인간이 선택한 잔여 아키텍처 프로토타입이 기계 중심 설계 탐색과 결합되어 결과적인 심층 신경망을 제공 ◆ COVID-Net 디자인은 프로젝션 확장 프로젝션 디자인 패턴을 많이 사용하여 높은 아키텍처 다양성과 선택적 장거리 연결성을 보여줍니다. 이 디자인은 인간 중심의 프로토타입 모델과 비교할 때 상당한 계산 비용을 발생시키지 않으면서 표현 능력을 향상 ◆ 모델은 Tensorflow에서 구현
매트릭	◆ 93.9 % PPV (Positive-Predictive Value) COVID-19 – 음성, Penumonic – 정밀도 점수가 높을수록 서로 다른 클래스에 대해 모델에서 예측한 대부분의 라벨이 정확함 ◆ 98.9 % 긍정-예측-값 (PPV) : COVID-19- 양성, 폐렴성 – 더 높은 정밀도 점수는 모델에서 서로 다른 클래스에 대해 예측한 대부분의 레이블이 정확함 ◆ 88.9 % 양의 예측 값 (PPV) : 비 폐성 (정상) – 정밀도 점수가 높을수록 다른 클래스에 대해 모델에서 예측한 대부분의 레이블이 정확함 ◆ 92 % 민감도 : COVID-19- 음성, Pneumonic – 더 높은 재현율 점수는 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측함 ◆ 93 % 민감도 : COVID-19 양성, Pneumonic – 더 높은 재현율 점수는 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측함 ◆ 96 % 민감도 : 비 음성 (정상) – 더 높은 재현율 점수는 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측함 ◆ 이 모델은 민감도와 양수 예측값 측면에서 CXR 데이터에 대한 최고 성능을 얻을 수 있음. ◆ 양수-예측 값 : 비유 폐성 (정상) 샘플의 경우 88.9 %, COVID-19- 음성 (폐렴성) 샘플의 경우 93.9 %, COVID-19- 양성 (폐렴성) 샘플의 경우 98.9 %, 유사하게 높은 감도 (96.0 %, 92.0 % 및 93.0 %). ◆ 해당 결과는 COVID-net이 시간 소모적인 역전사 효소-중합 효소 연쇄 반응 (RT-PCR) 테스트에 의존하지 않고도 COVID-19를 다른 폐렴 사례와 구별할 수 있음을 나타냄

◉ 이미지 분류 (Image Classification (Top 1/5 Accuracy, Top 1/5 Robustness Accuracy))

【 Overview 】

개요	◆ Modzy의 모델을 사용한 해당 모델은 이미지의 각 개체를 ImageNet 데이터 세트에서 사용할 수 있는 계층 구조로 구성된 1,000개의 일반 개체 클래스 중 하나로 분류 ◆ 해당 모델은 가능한 적대적 공격을 방어할 수도 있음 ◆ 모든 크기의 JPEG 이미지를 허용하며, 각 예측에 대한 설명 가능성 개체와 함께 가장 높은 신뢰도를 가진 상위 5개 예측을 개체 계층 정보도 포함하는 JSON 파일로 출력
데이터	◆ 해당 모델은 120만 개의 이미지와 1,000개의 서로 다른 객체 클래스로 구성된 대규모 이미지 데이터 세트인 ImageNet 데이터 세트에서 학습하였으며, Lyapunov 기반의 강력한 솔루션을 사용하여 훈련 ◆ 훈련은 1개의 DGX-1 GPU에서 51일이 소요되었으며, 모델은 학습률이 0.01이고 모멘텀이 0.9인 확률적 경사 하강법을 사용하여 120만 개의 학습 이미지에서 100 에포크에 대해 학습 ◆ 모델의 성능은 50,000개 이미지의 유효성 검사 데이터 세트에서 테스트 되었으며 최첨단 최고 정확도 0.67과 최고 5 정확도 0.86을 나타냄 ◆ 다양한 적대적 공격에 의해 생성된 50,000개의 적대적 이미지로 구성된 종합적으로 생성된 적대적 데이터 세트에서 최첨단 1대 견고성 정확도 0.68 및 최고 5 견고성 정확도 0.86을 획득
모델	◆ 이 모델은 Microsoft Research에서 처음 개발 및 제시한 ResNet50 이라는 잔류 신경망을 사용 ◆ ResNet50은 잔차 학습을 사용하므로 매우 깊고 훈련 데이터 세트에서 많은 기능을 학습할 수 있는 네트워크로 이어짐 ◆ 이 딥 러닝 모델에서 학습한 기능은 네트워크 내부의 각 하위 블록 끝에 표시되는 저수준, 중간 수준 및 고수준 기능이며, 이러한 특성은 이전 계층에서 학습한 특성을 빼는 것으로 간단히 이해할 수 있는 잔여 특성임 ◆ 이 모델에서 학습한 기능은 이미지의 객체 클래스를 대표할 뿐만 아니라 적대적 공격에 대해서도 강력함 ◆ 해당 모델은 TensorFlow 딥 러닝 프레임 워크를 사용하여 개발 ◆ 해당 모델의 강점 중 일부는 이미지에 제시된 상위 5개 적절한 객체 클래스를 찾는 기능과 함께 다양한 크기 및 픽셀 분포의 광범위한 이미지에 대한 객체 클래스를 감지하고 분류하는 기능을 포함 ◆ 입력 : image.jpg, png (Max 50MB) / 출력 : results. json (Max 1MB)
매트릭	◆ 적대적 방어 : 이 모델에는 적대적 방어 기능이 내장되어 있음 ◆ 설명 가능 :이 모델에는 설명 기능이 내장되어 있음 - 67% 상위 1개 정확도 - 86% 상위 5개 정확도 - 68% Top 1개 견고성 정확도 - 86% 상위 5개 견고성 정확도 ◆ 상위 1개 정확도 : 총 입력 샘플 수에 대한 상위 1개 예측 클래스의 올바른 예측 수의 비율 ◆ 상위 5개 정확도 : 분류자가 만든 상위 5개 예측의 비율 ◆ 상위 1개의 견고성 정확도 : 종합적으로 생성된 적대적 데이터 세트에 대한 분류기의 정확도 ◆ 상위 5개 견고성 정확도 : 종합적으로 생성된 적대적 테스트 데이터 세트에서 분류자가 만든 상위 5개 정확도 중 일부

◉ 물체 감지 (General Object Detection in Overhead Imagery (60-class mAP))

【 Overview 】

개요	◆ 항공 이미지에서 물체를 빠르고 정확하게 식별하는 기능은 도시 계획, 작물 감시 및 교통 감시와 같은 다양한 시나리오에서 유용 ◆ 이 모델은 주석이 달린 고해상도 위성 이미지의 가장 크고 최고 품질의 공개 데이터 세트 중 하나를 사용하여 60 가지 유형의 객체 (버스, 차량 부지, 건물, 유조선 등)에 대해 식별할 수 있도록 훈련 ◆ 총 면적이 45,000 평방 킬로미터가 넘는 이 데이터 세트에는 60개의 객체 클래스 각각의 다양한 변형이 포함되어 있어 강력한 모델이 생성됨 ◆ 이 모델은 오픈 소스이지만 Modzy 데이터 과학 팀에 의해 개발되었음
데이터	◆ 학습 세트는 공개 xView2 데이터 세트에서 대체 없이 무작위로 샘플링된 원본 이미지와 주석의 80%로 구성 ◆ YOLT 네트워크의 창 크기인 416 x 416 픽셀에 맞도록 이미지를 조각화하고 기본 해상도로 처리 ◆ 물체가 없는 이미지는 폐기
모델	◆ 이 모델은 오버 헤드 전기 광학 (EO) 위성 이미지 내에서 60가지 종류의 물체를 감지 ◆ 오픈 소스 SIMRDWN 프레임 워크에서 제공하는 YOLT2라는 YOLO의 개조된 버전을 사용 ◆ YOLT2는 위성 이미지에 맞게 조정된 파이프 라인으로, 더 큰 컨볼루션 필터가 더 작은 3x3 필터로 대체되어 먼 거리에서 작은 물체를 감지하는 모델의 기능을 개선 ◆ 이 모델은 공개 xView2 데이터 세트를 사용하여 학습 및 검증되었으며 TIFF, PNG 또는 JPEG 이미지를 입력으로 허용 ◆ 감지된 경계 상자와 해당 개체 클래스 이름 및 해당 신뢰 점수가 포함된 JSON 파일을 반환합니다. ◆ 입력 : input.png, jpg, jpeg, tiff (Max 100MB) / 출력 : results. json (Max 1MB) ◆ 입력 파일은 3 채널 전기 광학 위성 이미지여야 함 ◆ 출력 파일 (results.json)에는 감지된 차량 경계 상자가 포함 ◆ 각 경계 상자에는 해당 클래스 이름, 신뢰도 점수 및 상자를 정의하는 왼쪽 상단 / 오른쪽 하단 x, y 좌표가 포함
하드웨어	◆ 빠른 추론 시간을 위해 해당 모델은 하나 이상의 GPU에 연결되어야 함
매트릭	◆ 23.2 % 60 등급 mAP - 모든 클래스에서 평균 정밀도 점수의 평균 ◆ 해당 모델은 자연 재해 전후의 건물 위치와 손상 점수가 주석으로 추가된 고해상도 위성 이미지로 구성된 공개 xView2 데이터 세트를 사용하여 훈련되고 검증 ◆ 해당 모델은 SIMRDWN에서 설명한 방법론을 사용하여 계산된 0.2319의 60등급 평균 정밀도 (mAP) 점수를 달성하였음 ◆ IoU (Intersection over Union) 임계 값 0.5는 대부분의 클래스에 사용되었으며 임계값 0.25는 차량과 같이 비교적 작은 개체에 사용 ◆ 해당 모델은 지상 샘플 거리가 0.3 미터인 전자 광학 위성 이미지에서 가장 잘 수행됨

◉ 도로 분할 (Road Segmentation (F1 Score, Precision, Recall, Pixcelwise, Accuracy))

【 Overview 】

개요	◆ CrowdAI의 도로 분할 모델은 최첨단 딥 러닝 및 이미지 분할 기술을 사용하여 Maxar 위성 이미지에서 도로를 정확하게 찾고 레이블을 지정 ◆ 탐지는 geoTIFF 마스크로 출력되며 출력을 평활화하고 오 탐지를 제거하는 데 사용되는 일부 후 처리 기술을 사용 ◆ 이 모델은 Maxar의 적용 범위에 따라 전 세계적으로 사용 가능
데이터	◆ 이 모델은 인구가 밀집된 모든 대륙의 다양한 국가 / 주, 지역, 생물 군계, 계절 및 기후에 걸쳐 25,000 개 이상의 Maxar 50cm 이미지 칩에 대해 훈련 ◆ 훈련 데이터에는 유연성을 극대화하기 위해 도시, 교외 및 농촌 지역이 혼합되어 포함 ◆ 적합한 위치 : 눈 덮힌 지역을 제외한 모든 지역. 이 알고리즘은 도시 및 교외 지역 (높은 건물이 도로를 가리지 않음)에서 가장 잘 수행되지만 시골 / 원격 지역에서도 작동 ◆ 교육 데이터에 포함된 상위 국가는 중국, 볼리비아, 일본, 멕시코, 인도네시아, 미국 (특정 순서 없음). ◆ 적절한 계절 : 모두, 그러나 눈이 많이 덮이는 것은 피해야 함 ◆ 생물 군계 : 알고리즘은 온대림, 열대 / 아열대 산림, 사막 / 숲, 초원이 가장 큰 범주를 나타내는 다양한 생물 군계에 대해 훈련 ◆ 해당 모델은 CrowdAI의 내부 Maxar 유효성 검사 세트, WorldView 및 GeoEye 별자리에서 가져온 이미지의 글로벌화 된 세트에 대해 유효성이 검증
모델	◆ 해당 모델은 입력 이미지를 분석하여 도로를 식별 ◆ 신경망은 "도로"또는 "도로가 아닌"모든 픽셀에 클래스를 할당하는 데 사용 ◆ 출력을 평활화하고 오 탐지를 제거하기 위해 일부 후 처리 기술이 사용되며, 다음 geoTiff 색상 오버레이가 생성 ◆ 이 알고리즘은 보도, 자전거 경로, 진입로, 주차장, 수로, 철도, 골프 코스의 경로, 삼림 벌채 경로, 항구, 해변과 같은 기능을 도로로 간주하지 않음 ◆ 이 알고리즘은 다음 기준을 충족하는 Maxar 이미지와 호환 ◆ 호환 가능한 대역 및 센서 : 8 대역 또는 4 대역 RGBN 이미지 : WorldView-2, WorldView-3, WorldView-4, GeoEye-1 ◆ 50cm / 픽셀 정교화 이미지 ◆ 팬 샤프닝 ON, DRA (Dynamic Range Adjustment) OFF, AComp (대기 보정) ON
매트릭	◆ 72 % F1 점수 ◆ 99 % 픽셀 단위 정확도 ◆ 73 % 정밀도 ◆ 73 % 리콜 ◆ 현재 버전의 CrowdAI 도로 감지기에서 알고리즘은 포장 도로에 대해 최상의 결과를 제공하나나 비포장 도로와 지저분한 도로가 종종 감지되지만 정확도가 낮아 이러한 도로 유형이 전체 도로 네트워크에서 분리될 수 있음 ◆ 픽셀 단위 정확도 - 예측 영역에서 올바르게 분류되거나 예측되는 픽셀의 비율을 측정 ◆ 정밀도 점수가 높으면 모델이 다른 클래스에 대해 예측 한 대부분의 레이블이 정확함 ◆ 재현율 점수가 높으면 모델이 찾을 예정인 대부분의 클래스에 대해 올바른 레이블을 찾고 예측한다는 것을 나타냄

◈ 【분석】 영상 이미지 객체인식 분류 모델

【 Metric 】

평가지표	mAP(mean Average Precision) ❶ 60-class mAP ❷ 871-class mAP
목표기준	mAP 65% 이상
시험결과	적합 (mAP 71%) ❶ 0.2319 60-class mAP, 다수 IOU 0.5 이상/최소 0.25 ❷ 0.367 mAP
시험조건	실제 물체와 intersection of unions (IOU)가 50% 이상이고 객체 종류가 정답인 경우
평가산식	산정식: X = A / B (A: 전체 시험된 객체의 AP의 합 B: 전체 시험된 객체의 수)

【 Data 】

데이터 원천		카메라 5개 객체가 포함된 이미지 8,181장과 얼굴 이미지 16,106장 ❶ 버스, 빌딩 등 60개 클래스로 구성된 TIFF, PNG, JPEG 416 x 416 pixels 위성 사진 xView2dataset ❷ 6,809장 로고 이미지
홀드아웃	훈련	PASCAL VOC 2007 + 2012 (train+validation) 8,181장, WIDER_FACE (train+validation) 16,106장
	검증	-
	시험	PASCAL VOC 2,007 test 2,727장, FDDB test 2,845장 (사례3 : 전체 20%를 시험 데이터로 사용)
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		5개 멀티 클래스 분류(human, car, motorbike, bicycle, face)

【 Model 】

알고리즘	MobileNet v2 + SSDlite ❶ YOLT2 ❷ YOLOv3
참조모델	-
파라미터	❷ learning rate 0.001
경량화	MobileNet으로 CNN 파라미터 90% 해당하는 Fully-Connected Layers 제거, 커널(3×3→1×1)과 채널 줄여 연산량 감소
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python3, C
프레임워크	pytorch, EN675 SDK ❶ SIMRDWN
AutoML	-
하드웨어	NPU 보드(EN6751X1 EVM) ❷ NVIDIA Tesla V100 GPU 55회 Epoch(에포크)

◈ 【분석】 음성파일 내 문자인식 모델

【 Metric 】

평가지표	F1 Score, Precision, Recall
목표기준	-
시험결과	91% F1 Score, 91% Precision, 91% Recall
시험조건	-
평가산식	-

【 Data 】

데이터 원천		유투브 뉴스 데이터셋(1,508 시간 분량 오디오 .wav 파일)
홀드아웃	훈련	전체 데이터의 70%
	검증	전체 데이터의 10%
	시험	전체 데이터의 20%
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		6개 멀티 클래스 (English, German, French, Spanish, Chinese, Russian)

【 Model 】

알고리즘	CNN(Convolutional Neural Network), RNN(Recurrent Neural Network) BLSTM(Bidirectional Long Short-Term Memory), VGG(Very Deep Convolutional Networks)
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	-
프레임워크	-
AutoML	-
하드웨어	-

◈ 【분석】 감정상태 분류 모델

【 Metric 】

평가지표	Recall
목표기준	-
시험결과	60% Recall
시험조건	-
평가산식	-

【 Data 】

데이터 원천		소셜미디어, 블로그 등에서 추출한 11,000개 텍스트 문서
홀드아웃	훈련	8,800개 문서
	검증	-
	시험	2,200개 문서
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		3개 멀티 클래스 (EPositive, Neutral. Negative)

【 Model 】

알고리즘	Recurrent Neural Network (RNN), Long Short Term Memory (LSTM)
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	Keras
AutoML	-
하드웨어	-

2 예측 모델

◈ 【분석】 자전거 대여 수요량 예측 모델

【 Metric 】

평가지표	RMSLE(Root Mean Squared Logarithmic Error)
목표기준	-
시험결과	1위 (RMSLE 0.33756), 2위(RMSLE 0.34821)
시험조건	-
평가산식	$RMSLE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(\log(p_i+1)-\log(a_i+1))^2}$ $p = Predicted,\ a = Actual$

【 Data 】

데이터 원천		날짜 및 시간, 기온, 습도, 풍속 등 워싱턴 DC의 자전거 대여 이력 데이터(2011년1월~2012년12월)
홀드아웃	훈련	10,886건 대여 이력 수치 데이터
	검증	훈련데이터의 25% 활용
	시험	6,493건 대여 이력 수치 데이터
크로스 검증		-
데이터 증강		-
전처리		데이터 타입 변경, 피처 추가, 결측치 처리, 이상치 처리
분류 클래스		-

【 Model 】

알고리즘	scikit-learn 라이브러리 활용 선형 회귀모델
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	-
AutoML	-
하드웨어	-

◈ 【분석】 보스턴 주택 가격 예측 모델

【 Metric 】

평가지표	MAE(Mean Absolute Error)
목표기준	-
시험결과	1위 (MAE 3.69578), 2위(MAE 3.89530)
시험조건	-
평가산식	$MAE = \frac{1}{N}\sum_{i=1}^{N}\lvert y_i - \hat{y}\rvert$

【 Data 】

데이터 원천		1970년 중반 보스턴 외곽 지역 범죄율, 지방세율 데이터
홀드아웃	훈련	404개 훈련 데이터
	검증	-
	시험	훈련 데이터에 활용되지 않은 데이터 102개 샘플
크로스 검증		K-fold cross-validation(K=5)
데이터 증강		-
전처리		각 피처 스케일 정규화(범죄율 0~1 사이, 월 1~12)
분류 클래스		-

【 Model 】

알고리즘	선형 회귀모델(Linear Regression)
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	-
프레임워크	-
AutoML	-
하드웨어	-

3 언어 모델

◉ 오디오 키워드 탐지 (Audio Keyword Spotting (Word Error Rate))

【 Overview 】

개요	◆ Modzy의 모델을 사용한 해당 모델은 오디오 파일의 음성 내에서 주어진 키워드 세트를 검색하고 발견되면 해당 키워드가 발생한 타임 스탬프를 반환 ◆ 이 기능은 오디오 및 비디오 녹화 내에서 관심있는 섹션과 엔티티를 식별하는 데 특히 유용할 수 있음
데이터	◆ 해당 모델은 Fisher , LibriSpeech , Switchboard 및 Common Voice English 데이터 세트와 함께 약 1,700 시간의 전사 된 WAMU (NPR) 라디오 프로그램에 대해 학습 ◆ 0.0001의 학습률과 128의 배치 크기를 사용하여 75 에포크 동안 학습 ◆ 학습 후에는 검증 손실이 가장 좋은 가중치가 선택 ◆ 해당 모델은 LibriVox 프로젝트의 읽기 오디오 북에서 파생된 약 1,000시간의 16kHz 영어 음성으로 구성된 LibriSpeech 클린 테스트 코퍼스에서 검증
모델	◆ 이 모델은 Deep Speech 알고리즘을 기반으로 하는 Mozilla에서 구현 한 DeepSpeech 라는 오픈 소스 Speech-to-Text 엔진을 사용 ◆ 이는 각각 2,048 개의 뉴런을 포함하는 5 개의 은닉층이 있는 순환 신경망 아키텍처를 사용 ◆ 입력 : input.wav(Max 100MB), word.txt (Max 1MB) ◆ 출력 : results.json (Max 1MB) ◆ 출력 파일에는 감지된 단어 발생과 다음 JSON 형식의 해당 타임 스탬프가 포함 [{"word": "keyword1", "start_time ": startTime, "duration": duration}, {"word": "keyword2", "start_time ": startTime, "duration": duration}]
하드웨어	◆ 해당 모델은 Quadro RTX 6000 GPU를 사용하여 학습
매트릭	◆ 7.5 % 워드 오류율 ◆ 해당 모델은 읽기 오디오 북에서 파생된 약 1,000시간의 영어 말하기로 구성된 LibriSpeech 클린 테스트 코퍼스에서 7.5 %의 단어 오류율을 달성하였음 ◆ 단어 오류율은 단어 수준에서 음성 인식 또는 기계 번역의 성능을 측정하며 Levenshtein 거리에서 파생

◈ 【분석】 오디오 파일 내 문자열 추출 모델

【 Metric 】

평가지표	Word Error Rate
목표기준	-
시험결과	8.22% Word Error Rate
시험조건	오디오 파일 중 키워드가 있는 타임스탬프 검색 정확도
평가산식	-

【 Data 】

데이터 원천		오디오 북에서 추출한 영어 스피치 .wav 파일 (Fisher, LibriSpeech, Switchboard 영어 16kHz 영어 스피치)
홀드아웃	훈련	Fisher(23,000명 화자 2,000시간), LibriSpeech(500명 화자 250시간), Switchboard(4,000명 화자 300시간)
	검증	5시간 분량 오디오(.wav)
	시험	5시간 분량 오디어(.wav)
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		-

【 Model 】

알고리즘	RNN(recurrent neural network) 5개 히든 레이어(각 레이어별 2,048개 뉴론으로 구성)
참조모델	오픈소스 Speech to Text 엔진 DeepSpeech
파라미터	75 epochs (Learning rate of 0.0001 and a batch size of 128)
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	-
AutoML	-
하드웨어	Quadro RTX 6000 GPUs

◉ 텍스트 요약 (Text Summarization (Rouge score))

【 Overview 】

개요	◆ Modzy의 모델을 이용한 해당 모델은 텍스트 기사를 몇 개의 문장으로 요약 ◆ 영어 텍스트 문서를 입력으로 받아 입력 텍스트의 요약을 반환 ◆ 이 모델은 미디어 모니터링, 뉴스레터 요약 생성, 책 요약 및 자동화된 콘텐츠 생성을 포함한 다양한 설정에서 사용할 수 있음
데이터	◆ 해당 모델은 해당 요약과 함께 CNN 및 Daily Mail의 약 312,085개의 온라인 뉴스 기사로 구성된 데이터 세트에서 학습 ◆ 평균적으로 기사의 길이는 781개이고 요약은 56개의 토큰 ◆ 모델의 성능은 CNN / Daily News 데이터 세트의 13,367개 기사로 구성된 검증 데이터 세트에서 테스트 되었음
모델	◆ 이 모델 솔루션은 Fast Abstractive Summarization-RL 모델에서 파생 ◆ 그것은 3중 구조를 가지고 있음 ◆ 첫째, 추상적인 요약을 위해 문장 수준의 RL 기법을 사용하여 어노테이션이 있는 단어의 일치여부에 대한 확인 없이 문장 계층 구조를 효과적으로 활용 ◆ 다음으로 요약 데이터 세트의 여러 버전과 테스트 전용 데이터 세트의 모든 측정 항목에 대해 새로운 최신 결과를 얻음 ◆ 이러한 결과는 언어 유창함의 손실없이 추출 및 추상 모드 모두에 대해 얻어짐 ◆ 마지막으로, 병렬 디코딩은 이전의 최고의 신경 추상화 요약 시스템에 비해 10 ~ 20 배의 속도 향상을 가져오게됨 ◆ 입력 : input.txt (Max 1MB) / 출력 : results. json (Max 1MB)
매트릭	◆ 해당 모델은 ROUGE 점수 0.33을 달성 ◆ 해당 모델은 CNN / Daily Mail 데이터 세트에서 학습 , 검증 및 테스트 되었으며 모델의 추출 및 추상화 단계 모두에 대해 ROUGE 지표가 평가 지표로 사용되었음 ◆ ROUGE (재현성 평가를 위한 회상 중심 Understudy) 측정 항목은 텍스트의 자동 요약 및 기계 번역을 평가하기 위한 측정 항목 집합 ◆ ROUGE (Recall-Oriented Understudy for Gisting Evaluation)는 자동으로 생성된 요약 / 번역을 사람이 만든 참조 세트와 비교하여 기계 번역 및 자동 요약을 평가하는 데 사용되는 일련의 메트릭

◈ 【분석】 영어문서 내용 요약 모델

【 Metric 】

평가지표	ROUGE(Recall-Oriented Understudy for Gisting Evaluation) score
목표기준	-
시험결과	0.33 ROUGE score
시험조건	-
평가산식	-

【 Data 】

데이터 원천		CNN 일간뉴스
홀드아웃	훈련	312,085개 온라인 뉴스 기사(평균 기사 사이즈는 781 토큰이고 평균 요약문은 56 토큰)
	검증	-
	시험	13,367개 기사
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		-

【 Model 】

알고리즘	-
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	-
AutoML	-
하드웨어	-

◉ 한영 번역 (Korean to English Translation (BLEU score))

【 Overview 】

개요	◆ Modzy의 모델을 이용한 해당 모델은 텍스트를 한국어에서 영어로 번역 ◆ UTF-8 한국어 텍스트를 입력으로 예상하고 영어 텍스트를 출력
데이터	◆ 해당 모델은 200,000단계에 대해 News-Commentary, QED, Bible, JW300, OpenSubtitles, Tatoeba, KPC 및 Tanzil 병렬 말뭉치에서 훈련 ◆ 오픈 소스 OpenNMT 프레임 워크를 사용하여 구현 ◆ 종교 텍스트의 대부분은 Opus에서 찾을 수 있음 ◆ 해당 모델의 검증은 2,000개의 병렬 문장에서 검증
모델	◆ 이 모델은 현재 많은 최첨단 번역 모델의 기반이 되는 Google Transformer 아키텍처를 사용 ◆ Transformer 모델의 핵심은 Attention이 있는 인코더-디코더 아키텍처 ◆ 다중 인코더는 자기주의 레이어로 구성된 각 인코더를 쌓아서 보고 있는 단어 대신 번역할 때 전체 문장을 고려하고 피드 포워드 신경망을 사용 ◆ 워드 임베딩은 이러한 인코딩 레이어를 통해 공급된 다음 디코딩 레이어로 전달됩니다. ◆ 디코딩 계층에서 자기주의 계층은 양방향을 허용하는 인코딩과 반대로 이전 위치에만 주의를 기울이게 됨 ◆ 그렇지 않으면 입력을 출력 언어로 디코딩하는 것을 제외하고는 동일한 방식으로 작동 ◆ 모든 유닛에는 추가 및 정규화 레이어도 있음 ◆ 표준 변압기 모델에는 8개의 어텐션 헤드가 사용되며, 이러한 결과는 피드 포워드 네트워크에 연결되고 올바른 크기로 축소 ◆ 위치 인코딩은 입력 시퀀스의 단어 순서를 설명하는데도 사용 ◆ 입력 : image.txt (Max 1MB) / 출력 : results.json (Max 1MB)
하드웨어	◆ 4개의 GPU 사용
매트릭	◆ 해당 모델은 한국 병행 코퍼스 2,000 문장으로 테스트 한 결과, Bleu 점수 10.22를 달성 ◆ Bleu는 번역 작업에 일반적으로 사용되는 메트릭이며 모델 생성 텍스트를 골드 표준과 비교하여 얼마나 유사한지 확인하는 방법임 ◆ 10.2 % Bleu Score – 한 언어에서 다른 언어로 기계 번역된 텍스트의 품질을 평가하는 방법 ◆ 기계 번역이 전문 인간 번역에 가까울수록 점수가 높아짐

◈ 【분석】 한국어 영어 번역 & 이미지 캡션(Caption) 모델

【 Metric 】

평가지표	Bleu Score
목표기준	-
시험결과	10.2% Bleu Score, ❶ 40.8% Bleu Score
시험조건	-
평가산식	-

【 Data 】

데이터 원천		News-Commentary, QED, bible, JW300, OpenSubtitles, Tatoeba, KPC, Tanzil
홀드아웃	훈련	❶ 300백만개 이미지
	검증	❶ 5,000개 이미지 (2014 COCO validation set)
	시험	2000개 문장 병렬 코퍼스
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		-

【 Model 】

알고리즘	❶ GRU RNN(Gated Recurrent Unit Recurrent Neural Network)
참조모델	Google Transformer(encoder-decoder architecture)
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	OpenNMT, ❶ ResNet-101
AutoML	-
하드웨어	4 Nvidia V100 GPU

◉ 다국어 광학문자 인식(Multi-Language OCR)

【 Overview 】

개요	◆ 오픈소스 모델을 이용한 해당 모델은 텍스트 삽입 이미지의 스캔 이미지를 전자 텍스트로 변환 ◆ JPG, PNG 및 기타 여러 형식을 포함한 여러 형식의 스캔 이미지를 입력으로 사용하며, 입력에는 테이블이 포함될 수 있음 ◆ PDF, TSV, 일반 텍스트 및 기타 형식으로 출력을 생성합니다. ◆ 모델은 또한 사용자 제공 패턴 및 단어, 107 개의 쓰기 시스템 (스크립트) 및 언어를 지원하나, 컬러 이미지를 처리하거나 필기를 인식하지 않음 ◆ 이 모델은 인쇄물, 보관 종이 문서 및 텍스트 이미지만 포함된 웹 페이지에서 전자 텍스트를 복구하는 등 다양한 방법으로 사용할 수 있음
데이터	◆ 훈련 데이터 세트에는 소량의 데이터가 포함되어 있음 ◆ 단일 크기의 8개 글꼴에서 94자 샘플 20개, 일반, 굵게, 기울임 꼴, 굵은 기울임 꼴의 4가지 속성으로 총 60,160개의 훈련 샘플을 제공 ◆ 해당 모델은 원본 비즈니스 편지 (319K 문자), DOE 샘플 (140만 문자), 잡지 샘플 (666K 문자), 영자 신문 (492K 문자) 및 스페인어 등 다양한 유형의 문서를 나타내는 여러 데이터 세트에 대해 테스트되었음 ◆ 신문 (34 만 8 천자). 일반적으로 두 가지 다른 스캔 해상도로 수행되는 이러한 각 테스트에서 메트릭에는 단어 및 문자 수준에서 오류 수와 정확도가 포함되어있음
모델	◆ 해당 모델은 구성 요소의 윤곽을 저장하고 윤곽을 대략적인 모양으로 수집한 다음 단어 인식을 위한 2단계 프로세스를 포함하는 여러 처리 단계를 사용 ◆ 각 단어를 인식하고 만족스러운 단어가 학습 데이터로 적응형 분류기에 전달 ◆ 입력 : input.txt, jpg, png (Max 1MB) / config.json (Max 1MB) ◆ 출력 : results. json (Max 1MB)
매트릭	◆ 96.6 % 워드 정확도 (300dpi 8 비트 그레이 스케일) 및 96.3 % 워드 정확도 (300dpi 흑백) ◆ 이 모델은 OCR 정확도의 제 4회 연례 테스트에서 측정된 300dpi 흑백으로 스캔 할 때 DOE에서 제공하는 표준 문서 모음에 대해 96.34%의 단어 정확도를 제공했고 300dpi 8비트 그레이 스케일로 스캔 할 때 96.62 %를 제공 ◆ 비즈니스 편지의 팩스 버전 (파인 모드 팩스)의 경우, 해당 모델은 95.30%의 단어 정확도를 제공 ◆ 이 모델은 여러 이미지 형식을 처리하고 테이블을 처리하며 페이지 분할을 수행 ◆ Levenshtein 거리를 사용하여 단어 수준에서 출력 텍스트가 참조 텍스트에 얼마나 가까운지를 측정 ◆ 참조 텍스트가 출력 텍스트의 하위 문자열이면 올바른 것으로 간주됨

◈ 【분석】 이미지 내 다국어 텍스트 정보 추출 모델

【 Metric 】

평가지표	Word Accuracy
목표기준	-
시험결과	96.6% Word Accuracy (300 dpi 8-bit gray scale) 96.3% Word Accuracy (300 dpi bitonal)
시험조건	-
평가산식	-

【 Data 】

데이터 원천		94개 문자열이 포함된 이미지 파일(.jpg, .png)로 8 폰트 사이즈, 4가지 속성(normal, bold, italic, bold italic)
홀드아웃	훈련	60,160개 샘플
	검증	-
	시험	비즈니스 편지(319K 캐릭터), 잡지(666K 캐릭터), 영어신문(492K 캐릭터), 스페인어 신문(348K 캐릭터)
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		-

【 Model 】

알고리즘	-
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	-
AutoML	-
하드웨어	-