정보통신산업진흥원
National IT Industry Promotion Agency

AI 솔루션 테스트 실무 가이드

목차

1강 AI 테스트 일반

I. 인공지능 솔루션 개요
II. 인공지능 솔루션 테스트
III. 인공지능 솔루션 구성요소

2강 AI 테스트 실무

2023 AI바우처 사업

Ⅰ 인공지능 솔루션 개요

- AI 솔루션 개념
- AI 솔루션 성숙도 분류
- AI 솔루션 개발 및 관리 프로세스

I. 인공지능 솔루션 개요

인공지능 솔루션 개념

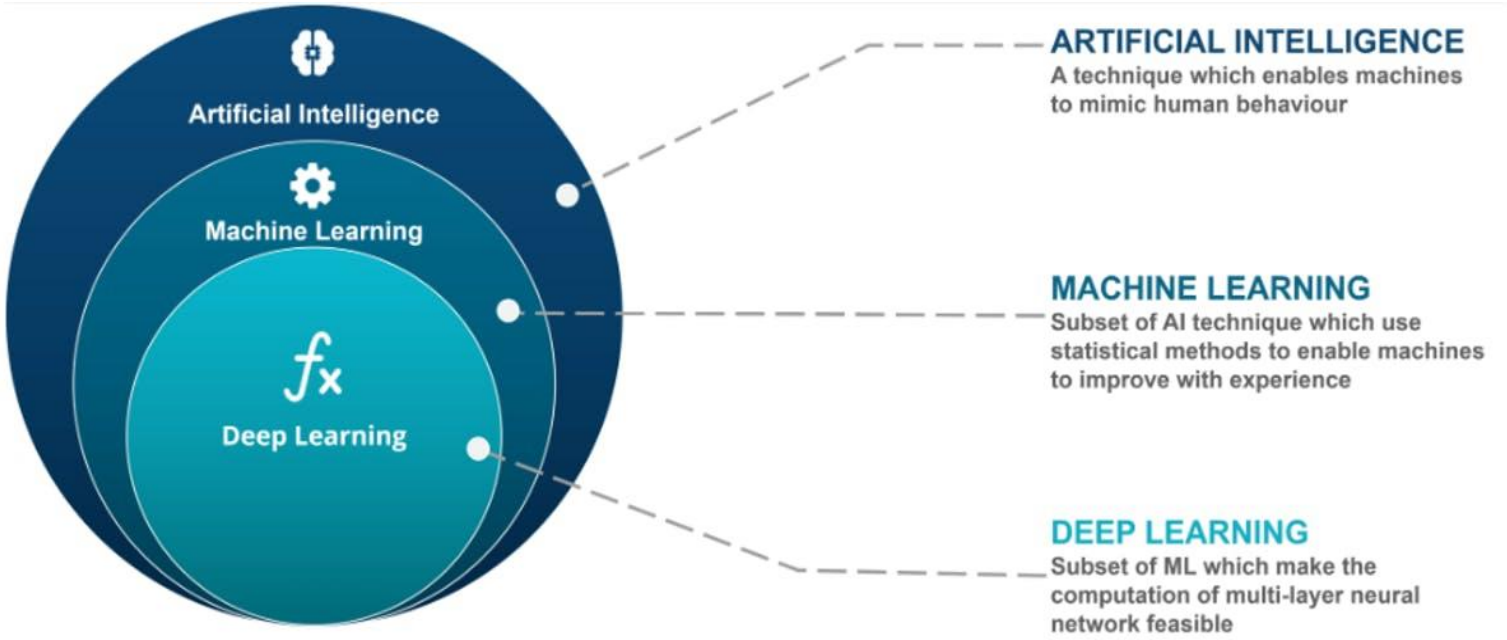

AI 바우처 사업에서 인공지능 솔루션이란?

: 인공지능 모델이 존재하는 <u>머신러닝과 딥러닝</u> 알고리즘에 기반한 솔루션

I. 인공지능 솔루션 개요

활용도에 따른 AI 솔루션 성숙도 분류

※ 인공지능 솔루션 테스트 대상 =

Prototype + Pilot + MVP

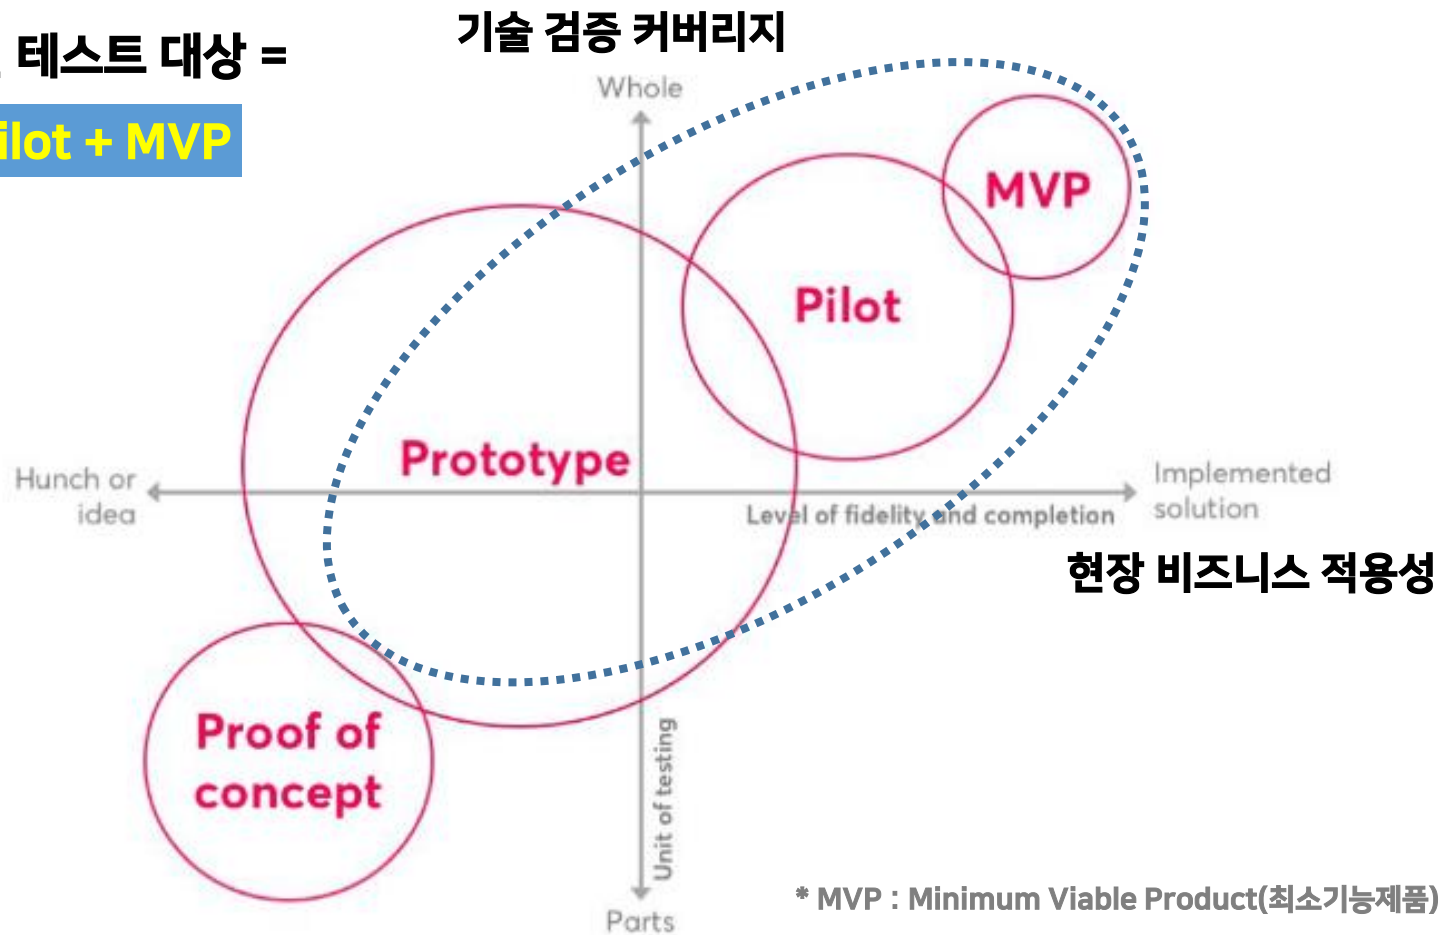

* MVP : Minimum Viable Product(최소기능제품)

I. 인공지능 솔루션 개요

MVP를 위한 반복적 개발 및 관리 프로세스

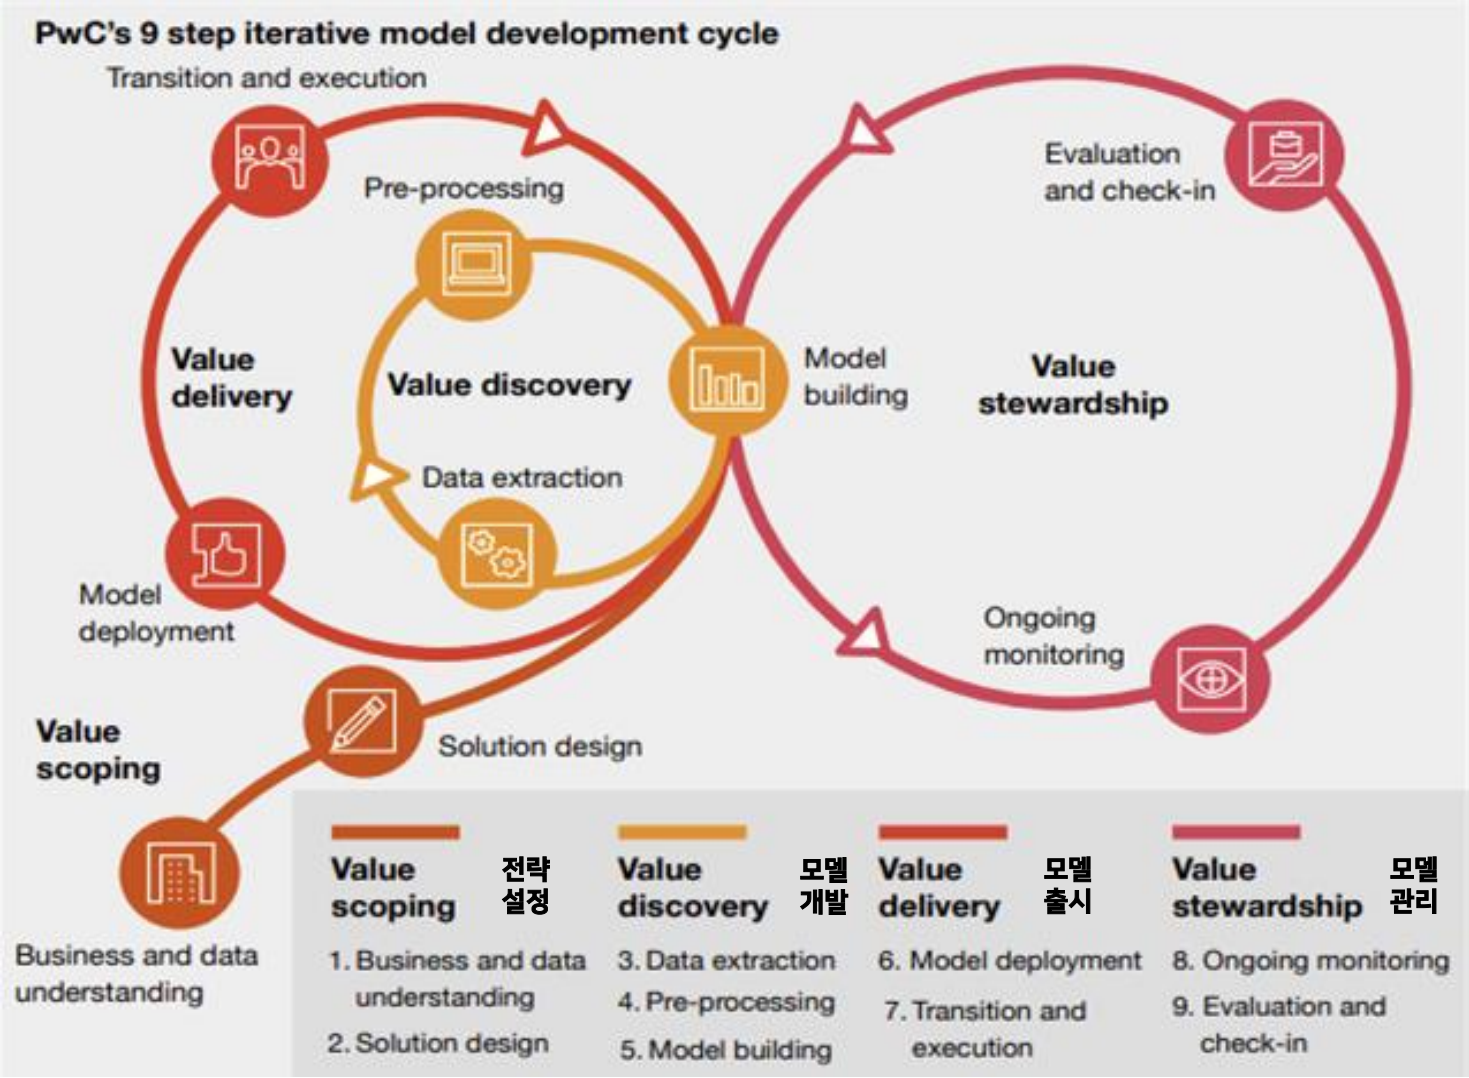

2023 AI바우처 사업

II 인공지능 솔루션 테스트

- AI 바우처 사업 핵심 전제 사항
- AI 바우처 공모안내서 관련 내용
- AI 모델 테스트의 어려움

II. 인공지능 솔루션 테스트

AI 바우처 사업에서의 솔루션 테스트

AI 바우처 사업

- 인공지능 솔루션을 수요기업이 활용하는 데 있어 필요한 자금을 지원하는 사업
- 공급기업의 인공지능 솔루션 및 모델 보유를 전제로 하는 사업

AI 솔루션 테스트 대상

- AI 솔루션 시험 대상 : 머신러닝 또는 딥러닝 인공지능 모델
- 포괄적 AI 범주에는 **Rule based 모델**도 포함되나 본 사업에서는 **AI 테스트 범주에 포함하지 않음**

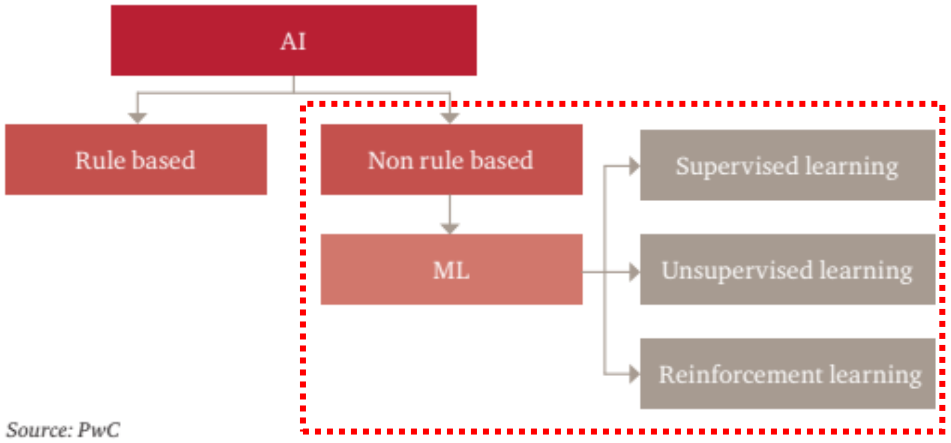

Source: PwC

AI 솔루션 시험 대상

II. 인공지능 솔루션 테스트

AI 바우처 공모안내서의 테스트 관련 요구사항

AI 바우처 공모안내서

- 공급기업이 제공하는 솔루션에 대해서는 **사업기간 내** 자체 시험결과가 아닌 **제3자가 수행한 테스트 결과서를 제출하여야함**

※ 단, 제출 테스트 결과서에는 성능목표, 학습/테스트데이터, 사용 알고리즘, 사용언어, 개발 프레임워크 등이 제시되어야 하며 KOLAS 인증 기업의 테스트 결과서만 허용

*기한내 미제출 시 참여제한, 사업비 환수 등 제재조치를 취할 수 있음

- 관련하여, 공모안내서의 인정 항목의 기타 경비에 **테스트 용역비가 추가**되어 공급기업은 사업비 내에서 테스트 수행에 따른 비용 집행이 가능

II. 인공지능 솔루션 테스트

인공지능 솔루션 테스트의 어려움

불충분한 데이터

- 학습 / 시험 데이터가 불충분하면 테스트 불가능
- 학습 데이터 부족은 데이터 생성기법 등을 통해 증강가능
- 교차 검증기법등을 통해 편향을 최소화 고려 필요

데이터 편향

- 편향된 데이터 통해 학습된 모델은 편향된 결과를 산출
- 데이터의 수, 편향, 특성 및 분포 미반영, 노이즈 제거 등 필요

데이터 품질문제

- 낮은 데이터 품질 → 결과 왜곡 발생
- 결측치, 이상치 등 처리 필요
- 스케일 다른 데이터 → 정규화 필요

목표 설정 문제

- 사용목적에 따른 성능목표 설정하지 않음
- 데이터 분포/편향에 종속적인 목표 설정

※ 정확도 : 학습데이터와 평가데이터가 유사할 수록 결과 왜곡

시험환경 미비

- AI 모델 테스트를 위한 준비의 미비
- 개발을 위한 도구활용, 모델 문서화, 테스트 케이스 및 문서 템플릿 등 준비 필요

2023 AI바우처 사업

III 인공지능 솔루션 구성요소

- 활용도에 따른 AI 바우처 솔루션 관점
- MVP 구현을 위한 Cycle

III. 인공지능 솔루션 구성요소

구성요소 : 매트릭(Matric) / 데이터(Data) / 모델(Model)

AI 솔루션의 핵심 구성요소인 AI 모델이 최적합으로 구현되어 있는지 검증하기 위해
적절한 매트릭 선정, 데이터 확보/정제, 인공지능 모델 최적화 및 테스트가 필수적임

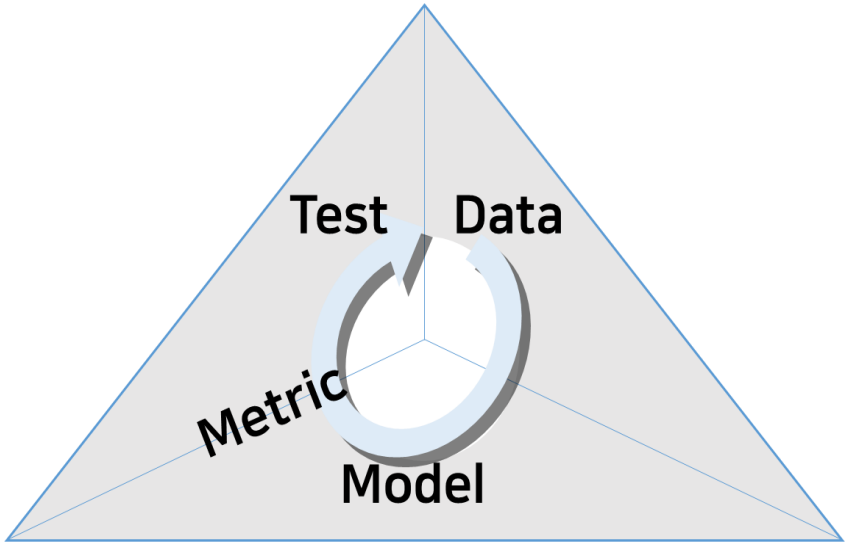

Data	• 목표에 맞는 Data 수집 • Feature Engineering • Cross Validation • 학습, 검증, 평가 데이터 분류 • Data 정제 및 희소 데이터 문제 해결 • 데이터 가공 품질 확보
Model	• 목표에 맞는 모델 선정 및 성능 향상 방법 • 앙상블 기법 • 하이퍼 파라메터 • 과소적합 해결 • 과대적합 해결
Metric	• 인공지능 모델 성능 평가 지표 • 유즈 케이스별 성능 평가 지표
Test	• 인공지능 모델의 목표에 맞는지 성능 평가 • 데이터, 매트릭, 모델의 적합성 확인

III. 인공지능 솔루션 구성요소

데이터(Data)

❑ 피처 엔지니어링 (Feature Engineering)

- 결측치, 이상치 등 데이터 품질문제 해결과 서로 다른 분포를 가지는 데이터 보정 작업 등을 피처 엔지니어링(Feature Engineering)이라 함

< 피처 엔지니어링 개념도 >

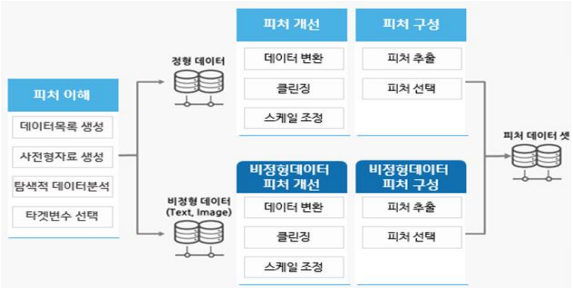

< 피처 엔지니어링 예시 >

방법	내용
결측치 보정	• 결측값은 데이터에 값이 없는 경우를 말하며, 가장 간단하게는 평균(Mean), 중앙값(Median), 최빈값(Mode)으로 채울 수 있으며 결측값이 너무 많은 경우 해당 피처를 삭제(Drop)할 수 있음 • 초기값(Default) 값이나 빈번하게 나타나는 값 또는 랜덤 값으로 채울 수 있음
이상값 처리	• 값이 존재할 수 있는 범위를 벗어나는 경우, 표준편차에서 예외적으로 나타내는 값들을 삭제하거나, 특정 Percentage외에 있는 값들을 삭제(상위 5% 또는 하위 5% 등)하여 처리
범주화 (Binning)	• Binning은 근처의 값들을 하나의 범주로 묶게 되면 좀더 견고한 모델을 얻게 되는데 예를 들어 40에서 50, 50에서 60, 60 이상 등 구간을 정해 그룹으로 처리
원-핫 인코딩 (One-Hot Encoding)	• 텍스트로 된 범주형 데이터를 학습에 이용하기 위해서는 숫자 타입으로 변형이 필요한데, 서울(1), 부산(2), 대전(3)으로 범주화하면 대전이 서울보다는 2보다 큰 무엇인가로 오해할 가능성이 생기기 때문에 데이터를 하나의 컬럼으로 만들고 해당 값이 있는지를 0과 1로 표현하는 방법
피처 스케일링 (Feature Scaling)	• 서로 다른 범위의 데이터들을 같은 범위로 묶어 학습하기 위해 데이터 범위를 0과 1 사이로 변환(정규화) • Normalization($\frac{x - x_{min}}{x_{max} - x_{min}}$), Standardization($\frac{x-\mu}{\sigma}$ (μ : 평균, σ : 표준편차))
로그 변형	• 나이와 재산의 관계를 볼 때, 나이는 1~100까지의 범주를 갖지만, 재산은 0원에서 수 조원까지 아주 넓게 분포할 수 있어 이런 데이터를 정규분포에 맞게 변형 시켜주는 것이 로그변환(Log-Transform)

❑ 교차 검증 (Cross Validation)

- 훈련(Train)과 시험(Test) 데이터로만 학습을 한 모델은 시험 데이터에 과대 적합할 수 있어 훈련 데이터 중 일부 데이터를 검증목적으로 활용하는 기법
  - * 다양한 상황이 있기 때문에 훈련 데이터 중 검증(Validation) 데이터 비중에 대한 정답은 없으나 훈련 대 검증 데이터 비중을 8:2 내외로 하는 경우가 다수
- 아래의 경우는 데이터를 5개의 부분집합으로 분할(K=5라 표현)한 후 각 분할마다 하나의 폴드를 시험용으로 사용하고 나머지 4개는 훈련용으로 사용
  - * 이러한 학습과정을 반복하여 각 분할마다 정확도를 높이게 됨

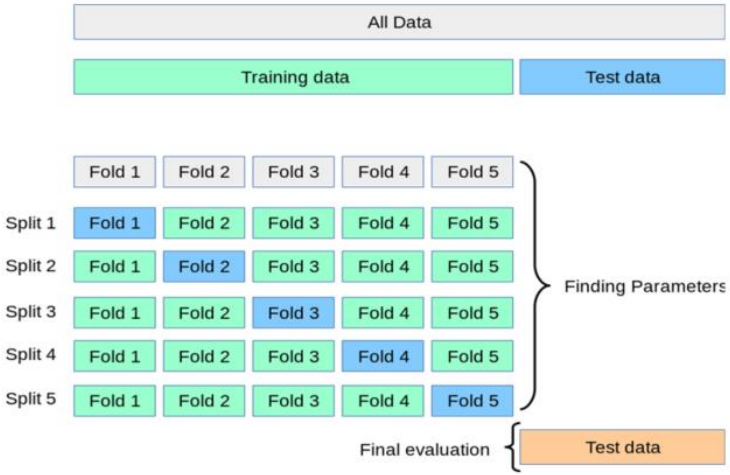

III. 인공지능 솔루션 구성요소

모델(Model) (1/2)

❑ 앙상블 (Ensemble)

○ 앙상블 학습(Ensemble Learning)은 여러 개의 분류기를 생성하고, 그 예측을 결합함으로써 보다 정확한 예측을 도출하는 기법

* 하나의 강력한 알고리즘보다 복수의 약한 알고리즘이 더 뛰어날 수 있다는 가정에 기반

< 앙상블 학습 유형 >

학습 유형	내용	개념도
보팅(Voting)	• 서로 다른 알고리즘의 모델들의 결과 중 다수의 결과를 최종 판단의 근거로 활용 하드 보팅 (Hard Voting): 분류 모델별 결과 중 다수 결과를 채택하는 방식으로 모델1(고양이), 모델2(개), 모델3(개)인 경우 개로 판정 소프트 보팅 (Soft Voting): 만약 모델1이 고양이 판정을 99%로 했고 모델2와 모델3은 개 판정을 51%로 했다면 소프트 보팅은 판정확률에 가중치를 부여하여 고양이로 판정	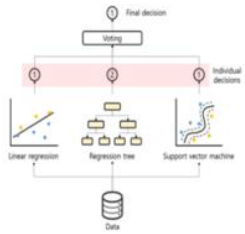
배깅(Bagging)	• 각각의 샘플을 여러 번 뽑아(Bootstrap) 각 모델을 학습시켜 결과를 집계(Aggregation)하는 방법 • 모두 같은 유형의 알고리즘을 사용하며, 대표적인 방식은 랜덤 포레스트(Random Forest) 방식	
부스팅 (Boosting)	• 여러 개의 약한 학습기(Week Learner)를 순차적으로 학습, 예측하면서 잘못 예측한 데이터에 가중치를 부여해 오류를 개선하는 학습 방식 • 배깅은 병렬로 학습하고, 부스팅은 순차적으로 학습하여 속도가 느린 반면 오류가 적음 • 대표적인 부스팅 알고리즘으로는 AdaBoot, GBM, XGBoost, LightGBM, CatBoost	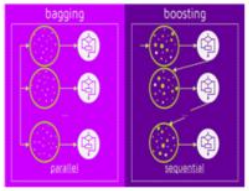
스태킹 (Stacking)	• 여러 모델들을 활용하여 각각의 예측 결과를 도출한 뒤 그 예측 결과를 결합해 최종 예측 결과를 만들어내는 방법	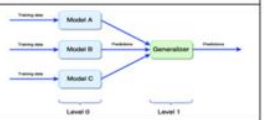

❑ 하이퍼파라미터 (Hyperparameter)

○ 최적의 딥러닝 모델 구현을 위해 학습률, 배치크기, 훈련 반복 횟수, 가중치 초기화 방법 등 **인간의 선험적 지식을 기반**으로 딥러닝 모델에 설정하는 변수

* 다양한 하이퍼파라미터가 존재하고 최적의 딥러닝 모델 생성을 위해 하이퍼파라미터 튜닝이 필수적

< 인공지능 하이퍼파라미터 개념 >

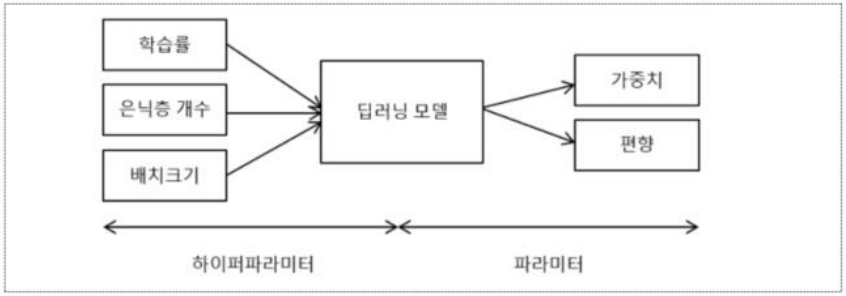

비교 항목	하이퍼파라미터	딥러닝 모델의 파라미터
사용 목적	모델링 최적화 파라미터값 도출	최적화된 딥러닝 모델 구현
생성 주체	사용자 판단 기반 생성	데이터 학습 모델이 생성
조정 여부	조정 가능	임의 조정 불가
활용 사례	– 학습률 – 경사하강법 반복 횟수 – 활성화 함수	– 인공신경망의 가중치 – SVM의 Support Vector – 선형회귀에서의 결정계수

* 파라미터는 딥러닝 모델에 의해 결정되지만 하이퍼파라미터는 휴리스틱 기반 사람이 직접 설정

* 하이퍼파라미터는 데이터 분석 결과로 얻어지는 값이 아니므로 절대적인 최적값은 존재하지 않음

III. 인공지능 솔루션 구성요소

모델(Model) (2/2)

< 인공지능 모델 파라미터 예시 >

종류	설명	적용 시 고려사항
학습률 (Learning Rate)	Gradient의 방향으로 얼마나 빠르게 이동할 것인지 결정하는 변수	너무 작으면 학습의 속도가 늦고, 너무 크면 학습 불가
손실 함수 (Cost Function)	입력에 따른 기대 값과 실제 값의 차이를 계산하는 함수	평균 제곱 오차 교차 엔트로피 오차
정규화(일반화) 파라미터 (Regularization parameter)	과적합(Overfitting)문제 회피 위해 L1 또는 L2 정규화 방법 사용	사용하는 일반화 변수도 하이퍼파라미터로 분류
미니 배치 크기 (Mini-batch Size)	배치셋 수행을 위해 전체 학습 데이터를 등분하는(나누는) 크기	가용 메모리 크기와 epoch* 수행 성능을 고려
훈련 반복 횟수 (Training Loop)	학습의 조기 종료를 결정하는 변수	학습 효율이 떨어지는 시점을 적절히 판단
은닉층의 뉴런 개수 (Hidden Unit)	훈련 데이터에 대한 학습 최적화 결정 변수	첫 Hidden Layer의 뉴런 수가 Input Layer 보다 큰 것이 효과적
가중치 초기화 (Weight Initialization)	학습 성능에 대한 결정 변수	모든 초기값이 0일 경우 모든 뉴런이 동일한 결과

* epoch(에포크) : 에포크는 같은 데이터셋으로 문제를 반복적으로 풀어보는 학습 방법으로 가중치를 갱신하면서 학습하며 같은 문제라도 학습상태(가중치)가 다르기 때문에 추가학습 가능

< 하이퍼파라미터 튜닝 기법 >

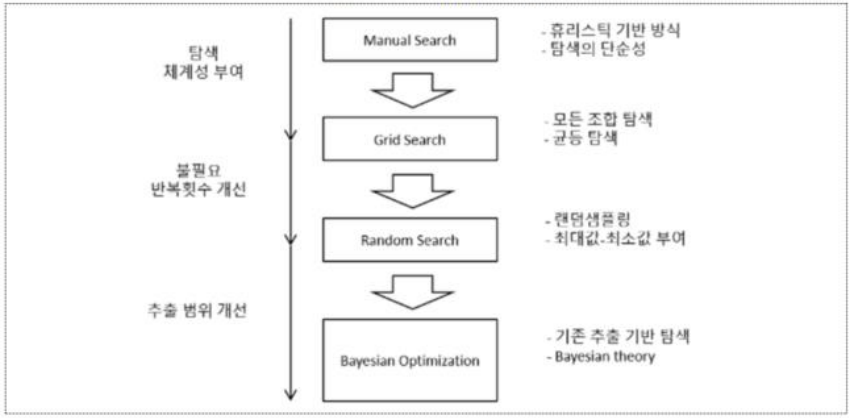

튜닝 기법	주요 활동	적용 방안
Manual Search	휴리스틱 조합	사용자의 직관과 경험 기반 탐색
	탐색의 단순성 적용	사용자 도출 조합 중 최적 조합 적용
Grid Search	모든 조합 탐색	하이퍼파라미터 적용값 전체 탐색
	시행 횟수 한계 파악	하이퍼파라미터 증가로 인해 전수 탐색 한계
Random Search	랜덤 샘플링	범위 내 무작위 값 반복 추출
	탐색 범위 부여	하이퍼파라미터 최소/최대값 부여
Bayesian Optimization	관측 데이터 기반 F(x) 추정	베이즈 정리 확용, 가우시안 프로세스
	함수 생성	확률 추정 결과 기반 입력값 후보 추천 함수

* 학습의 규모가 커질수록 탐색 시간 기반 Bayesian Optimization이 가장 뛰어나지만, 생성 모델 수준을 고려하여 상황에 맞는 튜닝 방법 선택이 필요
* 하이퍼파라미터의 적절한 튜닝을 통해 최적의 딥러닝 파라미터 도출 가능

III. 인공지능 솔루션 구성요소

매트릭(Matric) (1/2)

❑ 오차행렬 (Confusion Matrix)

- 오차행렬이란 학습을 통한 예측 성능을 측정하기 위해 예측 값과 실제값을 비교하기 위한 표로서 인공지능 분류 모델 매트릭 산정을 위한 기준 데이터

  * 의료판독 AI가 질병을 양성으로 예측하고 실제 환자가 양성이라면 True Positive가 됨

구분		인공지능 학습모델 예측 값	
		Positive	Negative
실제값	Positive	True Positive (TP, 정답)	False Negative (FN, 오답)
	Negative	False Positive (FP, 오답)	True Negative (TN, 정답)

❑ 오차행렬 기반 인공지능 분류모델 매트릭

매트릭	내용	산식
Accuracy (정확도)	• 인공지능 모델의 성능을 직관적으로 나타내는 지표로서 인공지능 모델이 True를 True라고 예측한 경우와 False를 False라고 예측한 정답의 비율 • 정확도는 데이터 분포에 크게 좌우되는데 만약 99% 데이터가 True인 상황에서 인공지능이 전체를 True라고 하는 경우 성능과 무관하게 매트릭 결과가 99%가 됨 • 오차행렬의 대각선 부분에 해당	TP FN FP TN $(Accuracy) = \frac{TP + TN}{TP + FN + FP + TN}$
Error Rate (오류율)	• 전체 중 오답 예측 비율 • 정확도와 반대되는 수치	$(Error\ Rate) = \frac{FP + FN}{TP + TN + FN + FP}$
Recall (재현율)	• 실제 Positive 중 인공지능 모델이 Positive로 찾은 비율 • 인공지능이 Positive를 찾을 수 있는 능력을 나타냄 • 오차행렬의 상단 행방향에 해당되며 Sensitivity(민감도) • 예) 질병이 있는 사람 중 질병이 있다고 판정받을 확률	TP FN FP TN $(Recall) = \frac{TP}{TP + FN}$
Specificity	• 전체 Negative 중 인공지능이 Negative로 찾은 비율	$Specificity = \frac{TN}{TN + FP}$
(특이도)	• 인공지능이 Negative를 찾을 수 있는 능력을 나타냄 • Positive를 찾는 능력을 계산하는 재현율과 달리 특이도는 Negative를 찾는 능력 • 예) 질병이 없는 사람 중 진짜 질병이 없다고 판정받을 확률 • 오차행렬의 하단 행방향에 해당	
Precision (정밀도)	• 모델이 Positive라 분류한 것 중 실제 Positive 비율 • 인공지능의 Positive 판정에 대한 신뢰도를 나타냄 • 오차행렬의 열방향에 해당	TP FN FP TN $(Precision) = \frac{TP}{TP + FP}$
F1 Score	• 정밀도와 재현율의 조화평균 • 분류대상 데이터 분포가 고르지 못한 경우 학습 데이터 분포에 따라 Accuracy(정확도) 수치가 왜곡될 수 있어 재현율과 정밀도 조화평균인 F1 Score를 사용	$(F1\text{-}score) = 2 \cdot \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$ 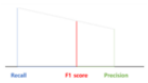

❑ PR (Precision-Recall) & mAP (mean Average Precision)

- PR 그래프는 **특정 알고리즘의 성능을 전반적으로 파악**하기에는 좋으나 서로 다른 두 알고리즘의 성능을 정량적으로 비교하기에는 한계*

  * 이를 보완하기 위해 나온 개념이 클래스 AP 평균인 mAP(mean Average Precision)으로 다수의 컴퓨터비전 분야 물체인식 알고리즘의 성능은 AP(Average Precision)로 평가

< PR(Precision-Recall) 그래프 >

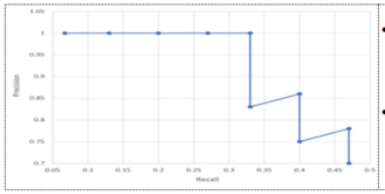

- 정밀도(Precision)와 재현율(Recall)은 반비례 관계로 두 지표 성능 변화 전체를 확인할 필요가 있고 이를 위해 PR 그래프를 이용함
- PR 곡선에서 x축은 recall 값이고, y축은 precision값으로 recall 값의 변화에 따른 precision값을 확인하여 전체적 성능 확인

❑ AUROC (Area Under the ROC Curve)

- Positive Rate 기준으로 100% TPR(True Positive Rate)이고 0% FPR(False Positive Rate) 인 경우 ROC 그래프의 면적은 1이 되며, 최소값은 0.5가 됨

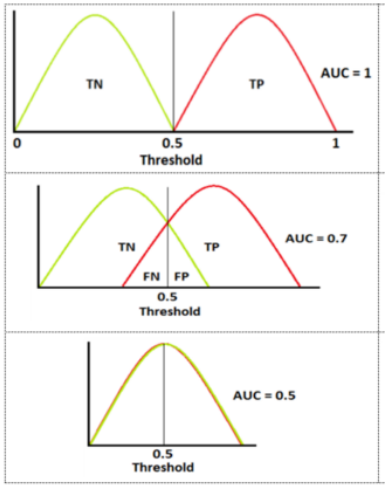

- 양성과 음성이 모두 정확히 분류되었기 때문에 오류로 인한 교집합은 없고 이 경우 AUC 면적은 1
- 양성과 음성 판정에 일부 오류가 있고 이 경우 AUC 면적은 0.5와 1사이가 됨
- 양성과 음성판정이 부정확한 상태로 AUC 면적은 최소값인 0.5가 됨

III. 인공지능 솔루션 구성요소

매트릭(Matric) (2/2)

❑ 예측모델 매트릭

○ 예측모델은 예측한 값과 실제값의 편차를 구하여 성능을 측정

매트릭	내용	산식
R2 Score (R-Squared)	• 데이터의 분산에 비례한 에러 값을 표현	$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_{pred} - y_{exp})^2}{\sum_{i=1}^{n}(y_{exp} - y_{mean})^2}$ $R^2 = \frac{\text{예측분산}}{\text{실제분산}}$
RMSE/RMSLE [Root Mean Square(Log) Error]	• 데이터와 예측값 간의 차이를 통해 예측력을 평가 – 예측값과 정답값 간의 표준편차	$RMSE: \sqrt{\frac{\sum_{i=1}^{n}(y_{pred} - y_{exp})^2}{n}}$
MAE(Mean Absolute Error)	• 데이터와 예측값 간의 차이를 통해 예측력을 평가 – 예측값과 정답값 간의 편차	$MAE: \frac{1}{n}\sum_{i=1}^{n}\lvert y_{pred} - y_{exp}\rvert$

❑ 영상인식

매트릭	내용	산식
IoU (Intersection over Union)	• 두 영역의 교차 영역의 넓이를 합 영역의 넓이로 나눈 값으로, 객체 검출에서 예측된 경계 상자의 정확도를 평가하는 지표 중 하나 • 예측된 경계 상자와 실제 참값(Ground Truth) 경계 상자의 IoU를 해당 경계 상자의 정확도로 간주 • 일반적으로 0.5 이상이면 제대로 검출(TP)되었다고 판단하며, 0.5 미만이면 잘못 검출(FP)되었다고 판단	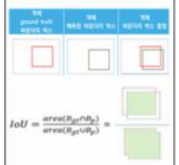 $IoU = \frac{area(B_{gt} \cap B_p)}{area(B_{gt} \cup B_p)} =$

❑ 기계번역

매트릭	내용	산식
BLEU(Bilingual Evaluation Understudy)	• 기계번역 결과와 사람이 직접 번역한 결과가 얼마나 유사한지 비교하여 번역에 대한 성능을 측정하는 방법이며, 측정 기준은 n-gram(단어 개수 카운트)에 기반	$BLEU = \min(1, \frac{\text{output length(예측 문장)}}{\text{reference length(실제 문장)}}) (\prod_{i=1}^{n} precision_i)^{\frac{1}{n}}$
ROUGE(Recall-Oriented Understudy for Gisting Evaluation)	• 텍스트 요약 모델의 성능 평가 지표로서 모델이 생성한 요약본 혹은 번역본을 사람이 미리 만들어 놓은 참조본과 대조해 성능 점수를 계산	(예) ROUGE-N: unigram, bigram, trigram 등 문장 간 중복되는 n-gram을 비교하는 지표
TF-IDF(Team Frequency-Inverse Document Frequency)	• TF(단어 빈도, term frequency)-IDF(역문서 빈도, inverse document frequency) 값이 높다면 다른 문서에는 많지 않고 해당 문서에서 자주 등장하는 중요 단어를 의미	TF-IDF = TF X IDF

❑ 음성인식

매트릭	내용	산식
WER(Word Error Rate)	• 단어의 오류율을 측정하는 지표 • 잘못 식별된 단어는 다음의 세 가지 범주로 분류 - 삽입(I) : 가설에 잘못 추가된 단어 - 삭제(D) : 가설에서 감지되지 않은 단어 - 대체(S) : 참조와 가설 사이에서 대체 된 단어	$WER = \frac{I + D + S}{N} * 100\%$
CER (Character Error Rate)	• 글자의 오류율을 측정하는 지표로 주로 조사를 사용하는 언어에 사용 • 인식률 = 100% - CER	CER(%) = 100 X [1 - (탈자 개수 + 오자 개수 + 첨자 개수) / 원본 글자수]

❑ 군집(Clustering)

매트릭	내용	산식
Silhouette Score	• 특정점(i)에서 인접한 클러스터의 모든 점과의 거리 평균(b(i))와 동일 클러스터내 모든 점과의 거리평균(a(i))의 차이를 a(i)와 b(i) 중 큰 값으로 나눈 지표 • a(i)=0 이면 최대값 1, b(i)=0이면 최소값 –1 이며, 0.5보다 큰 값일 경우 결과가 타당한 것으로 평가됨	$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$
Dunn Index	• 군집간 거리 최소값을 군집내 거리 최대값으로 나눈 지표로 밀집되고 군집간 거리가 멀수록 커짐	$I(C) = \frac{\min_{i,j}\{d_i(C_i, C_j)\}}{\max_{1 \le k \le n}\{\triangle(C_i)\}}$

❑ GAN (Generative Adversarial Network)

매트릭	내용	산식
IS(Inception Score)	• IS는 GAN의 성능을 측정하기 위해 생성된 이미지의 Quality와 Diversity 두 가지 기준을 고려 • IS가 높을수록 좋은 성능을 낸다고 해석할 수 있음	$IS(G) = \exp(\mathbb{E}_{x \sim p_g} D_{KL}(p(y\lvert x) \lVert p(y)))$
FID(Frechet Inception Distance)	• Inception Network의 중간 레이어에서 Feature를 가져와 이를 활용함 • 실제 데이터의 분포를 활용하지 않는 단점을 보완해 실제 데이터와 생성된 데이터에서 얻은 Feature의 평균과 공분산을 비교하는 식으로 구성 • IS보다 Noise에 강하며, 낮을수록 좋은 성능을 낸다고 해석할 수 있음	$FID(x, g) = \lVert\mu_x - \mu_g\rVert_2^2 + Tr(\Sigma_x + \Sigma_g - 2(\Sigma_x\Sigma_g)^{\frac{1}{2}})$

III. 인공지능 솔루션 구성요소

테스트

❑ 인공지능 모델 테스트 절차

○ 인공지능 제품품질은 인공지능 모델 성능 지표 달성과 소프트웨어 제품 자체의 기능적합성 등을 통칭하며 본 가이드에서는 **인공지능 모델로 대상을 국한함**

< 인공지능 모델 기능 테스트 프로세스 >

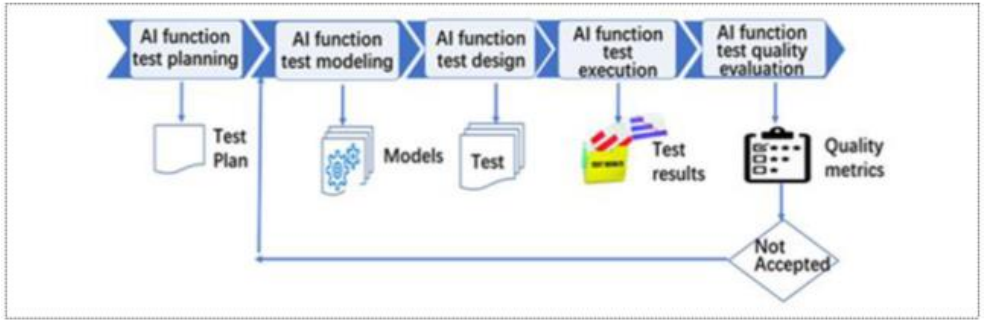

단계	내용
테스트 계획	• 인공지능 기능 식별, 분류하고 기능 요구사항에 대해 구체화하여 정의 • 테스트 대상 모델과 매트릭 정의
테스트 모델링	• 시험 데이터 교차검증, 시험도구 선택, 인프라 시험환경 계획
테스트 설계	• 시스템 입력(텍스트, 이미지, 오디오, 영상)과 출력에 기반한 테스트케이스 상세 설계
테스트 실행	**• 시험환경 점검, 테스트케이스 실행, 시험결과 기록, 시험성적서 제출 등 테스트 실행**
결과 검토	**• 테스트 범위가 충분하고 결과가 품질목표를 달성하였는지 평가**

○ (테스트결과서) 사업수행기업이 스스로 제3자 테스트 결과서 제출해야하며, 이 때 KOLAS 인증 기업의 테스트 결과서만 허용

* 테스트 수행에 필요한 경비에 대해서는 기타 경비로 사업비(용역) 집행 가능하며 시험성적서는 테스트결과서 제출 목적 외 전담기관의 인증 등을 의미하지는 않음에 유의

목차

1강 AI 테스트 일반

2강 AI 테스트 실무

I. 테스트 개요

II. 인공지능 모델 문서화 사례

III. 자주 묻는 질문

2023 AI바우처 사업

I 테스트 개요

- 인공지능 솔루션 테스트 개요

I. 테스트 실무 개요

인공지능 테스트 결과서 개요

테스트 결과서에 포함되어야 할 내용

✓ 기본적으로 솔루션명(버전), 시험주체/일자, 성능목표(매트릭), 알고리즘, 데이터(훈련/검증/시험), 시험환경/도구, 모델개선 방법/결과, 기타 시험조건/전제 등이 포함되어야 함

테스트 결과서 발급 주체 (발급자)	▪ 공급기업과 수요기업을 제외한 제3자 기업/기관에서 테스트를 진행하여 제출 가능 *KOLAS 인증 기관을 통해서 발급한 테스트결과서만 인정

2023 AI바우처 사업

II 인공지능 모델 사례

- 분류 모델
- 예측 모델
- 언어 모델

II. 인공지능 모델 사례

분류 모델 - 침입자 및 차량 감지

◉ 침입자 및 차량 감지(Intruder and Vehicle Detection)

【 Overview 】

개요	• 해당 모델은 이미지에서 사람과 차량을 식별 • 최소 480p 해상도에서 가장 잘 작동하지만 모든 jpg 또는 png 이미지를 입력으로 허용 • 위치, 신뢰도 및 감지 유형 (사람 또는 차량 카테고리)이 포함된 JSON을 출력 • 이 모델은 어둡고 흐릿하고 가려진 이미지에서도 작동하며 실시간 카메라 모니터링과 포렌식 데이터 분석 모두에 효과적임
데이터	• 해당 모델은 50 만개 이상의 범죄 및 보안 카메라 이미지에 대한 Actuate의 사내 데이터 세트를 사용하여 훈련 및 테스트 • 1,000개 이상의 보안 카메라 동영상을 포함하여 100,000 개의 고유한 이미지를 학습에 사용하고 겹치지 않는 다른 100,000개를 테스트에 사용 • 150 만 개 이상의 객체 인스턴스가 포함된 오픈 소스 데이터 세트 인 COCO의 전이 학습을 적용
모델	• 오픈 소스 기계 학습 플랫폼 인 YOLOv4 1 단계 감지 모델의 Actuate 독점 포크를 사용 • Actuate의 사용자 지정에는 모델의 기본 Darknet 프레임 워크, 네트워크 구조, 확장 및 풀링 매개 변수에 대한 수정이 포함 • 이를 통해 실시간 성능을 유지하면서 복잡하고 품질이 낮은 이미지에서 총기 감지 • 시스템 간 호환성을 유지하기 위해 PyTorch를 사용하여 실행 • 동적 학습률과 확률적 경사 하강 법을 사용하여 훈련
하드웨어	• 8x Nvidia Tesla V100 GPU에서 훈련하는 데 50 시간 소요
매트릭	• 이미지 당 전체 테스트 데이터 세트에서 96% 정밀도 및 97% 재현율을 달성 • 테스트 비디오 샘플에서 사람과 차량을 식별하는 99% 이상의 리콜을 달성하며, fps가 높을수록 성능이 향상 • 이 모델의 강점에는 저해상도 이미지, 야간 투시경 시나리오, 악천후, 장거리, 관심있는 사람 또는 차량이 빠르게 움직이거나 흐릿하거나 대부분 가려진 경우를 포함하여 어려운 환경에서 사람과 차량을 감지하는 기능이 포함 • 99% Accuracy - 분류자에 의해 만들어진 정확한 예측의 비율. 정확한 예측 수를 총 예측 수로 나누어 계산 • 97% F1 Score - 최고 값이 1 인 정밀도 및 재현율의 조화 평균 두 메트릭 간의 균형을 측정

◈ 【분석】 영상 이미지 내 침입자와 차량인식 모델

【 Metric 】

평가지표	Accuracy, F1 Score (사례2 : Recall, Precision, F1 Score)
목표기준	-
시험결과	99% Accuracy, 96% Precision, 97% Recall, 97% F1 Score (사례2 : 0.95 Precision, 0.95 Recall, 0.95 F1 Score)
시험조건	-
평가산식	-

【 Data 】

데이터 원천		50만장 이상의 보안 카메라와 범죄 이미지 (사례2 : ResNet50 으로 학습한 196개 자동차 클래스 5000 x 5000 pixel RGB, JPEG or PNG)
홀드아웃	훈련	중복 없는 100,000장 학습 이미지 (사례2 : ResNet으로 학습한 196개 자동차 클래스 16,185장 이미지 중 절반인 8,144장을 훈련 데이터로 사용)
	검증	-
	시험	중복 없는 100,000장 시험 이미지(1,000개 카메라 영상 포함) (사례2 : ResNet으로 학습한 196개 자동차 클래스 16,185장 이미지 중 8,041장을 시험 데이터로 사용)
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		-

【 Model 】

알고리즘	YOLOv4
참조모델	COCO(99%+ Recall, 98% precision 성능수준의 사람과 차량영상 인식 모델)
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	PyTorch
AutoML	-
하드웨어	8x Nvidia Tesla V100 GPUs 50시간 학습

II. 인공지능 모델 사례

예측 모델

◈ 【분석】 자전거 대여 수요량 예측 모델

【 Metric 】

평가지표	RMSLE(Root Mean Squared Logarithmic Error)
목표기준	-
시험결과	1위 (RMSLE 0.33756), 2위(RMSLE 0.34821)
시험조건	-
평가산식	$RMSLE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(\log(p_i+1)-\log(a_i+1))^2}$ $p = Predicted,\ a = Actual$

【 Data 】

데이터 원천		날짜 및 시간, 기온, 습도, 풍속 등 워싱턴 DC의 자전거 대여 이력 데이터(2011년1월~2012년12월)
홀드아웃	훈련	10,886건 대여 이력 수치 데이터
	검증	훈련데이터의 25% 활용
	시험	6,493건 대여 이력 수치 데이터
크로스 검증		-
데이터 증강		-
전처리		데이터 타입 변경, 피처 추가, 결측치 처리, 이상치 처리
분류 클래스		-

【 Model 】

알고리즘	scikit-learn 라이브러리 활용 선형 회귀모델
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	-
AutoML	-
하드웨어	-

◈ 【분석】 보스턴 주택 가격 예측 모델

【 Metric 】

평가지표	MAE(Mean Absolute Error)
목표기준	-
시험결과	1위 (MAE 3.69578), 2위(MAE 3.89530)
시험조건	-
평가산식	$MAE = \frac{1}{N}\sum_{i=1}^{N}\lvert y_i - \hat{y}\rvert$

【 Data 】

데이터 원천		1970년 중반 보스턴 외곽 지역 범죄율, 지방세율 데이터
홀드아웃	훈련	404개 훈련 데이터
	검증	-
	시험	훈련 데이터에 활용되지 않은 데이터 102개 샘플
크로스 검증		K-fold cross-validation(K=5)
데이터 증강		-
전처리		각 피처 스케일 정규화(범죄율 0~1 사이, 월 1~12)
분류 클래스		-

【 Model 】

알고리즘	선형 회귀모델(Linear Regression)
참조모델	-
파라미터	-
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	-
프레임워크	-
AutoML	-
하드웨어	-

II. 인공지능 모델 사례

언어 모델

◉ 오디오 키워드 탐지 (Audio Keyword Spotting (Word Error Rate))

【 Overview 】

개요	• Modzy의 모델을 사용한 해당 모델은 오디오 파일의 음성 내에서 주어진 키워드 세트를 검색하고 발견되면 해당 키워드가 발생한 타임 스탬프를 반환 • 이 기능은 오디오 및 비디오 녹화 내에서 관심있는 섹션과 엔티티를 식별하는 데 특히 유용할 수 있음
데이터	• 해당 모델은 Fisher , LibriSpeech , Switchboard 및 Common Voice English 데이터 세트와 함께 약 1,700 시간의 전사 된 WAMU (NPR) 라디오 프로그램에 대해 학습 • 0.0001의 학습률과 128의 배치 크기를 사용하여 75 에포크 동안 학습 • 학습 후에는 검증 손실이 가장 좋은 가중치가 선택 • 해당 모델은 LibriVox 프로젝트의 읽기 오디오 북에서 파생된 약 1,000시간의 16kHz 영어 음성으로 구성된 LibriSpeech 클린 테스트 코퍼스에서 검증
모델	• 이 모델은 Deep Speech 알고리즘을 기반으로 하는 Mozilla에서 구현 한 DeepSpeech 라는 오픈 소스 Speech-to-Text 엔진을 사용 • 이는 각각 2,048 개의 뉴런을 포함하는 5 개의 은닉층이 있는 순환 신경망 아키텍처를 사용 • 입력 : input.wav(Max 100MB), word.txt (Max 1MB) • 출력 : results.json (Max 1MB) • 출력 파일에는 감지된 단어 발생과 다음 JSON 형식의 해당 타임 스탬프가 포함 [{"word": "keyword1", "start_time ": startTime, "duration": duration}, {"word": "keyword2", "start_time ": startTime, "duration": duration}]
하드웨어	• 해당 모델은 Quadro RTX 6000 GPU를 사용하여 학습
메트릭	• 7.5% 워드 오류율 • 해당 모델은 읽기 오디오 북에서 파생된 약 1,000시간의 영어 말하기로 구성된 LibriSpeech 클린 테스트 코퍼스에서 7.5%의 단어 오류율을 달성하였음 • 단어 오류율은 단어 수준에서 음성 인식 또는 기계 번역의 성능을 측정하며 Levenshtein 거리에서 파생

◈ 【분석】 오디오 파일 내 문자열 추출 모델

【 Metric 】

평가지표	Word Error Rate
목표기준	-
시험결과	8.22% Word Error Rate
시험조건	오디오 파일 중 키워드가 있는 타임스탬프 검색 정확도
평가산식	-

【 Data 】

데이터 원천		오디오 북에서 추출한 영어 스피치 .wav 파일 (Fisher, LibriSpeech, Switchboard 영어 16kHz 영어 스피치)
홀드아웃	훈련	Fisher(23,000명 화자 2,000시간), LibriSpeech(500명 화자 250시간), Switchboard(4,000명 화자 300시간)
	검증	5시간 분량 오디오(.wav)
	시험	5시간 분량 오디어(.wav)
크로스 검증		-
데이터 증강		-
전처리		-
분류 클래스		-

【 Model 】

알고리즘	RNN(recurrent neural network) 5개 히든 레이어(각 레이어별 2,048개 뉴론으로 구성)
참조모델	오픈소스 Speech to Text 엔진 DeepSpeech
파라미터	75 epochs (Learning rate of 0.0001 and a batch size of 128)
경량화	-
앙상블	(예) Voting / Bagging / Boosting / Stacking
개발언어	Python
프레임워크	-
AutoML	-
하드웨어	Quadro RTX 6000 GPUs

2023 AI바우처 사업

III 자주 묻는 질문

IV. 상담 사례

제 3자 기업의 기준은 어떻게 되나요?

- 사업을 진행하고 있는 공급기업과 수요기업을 제외한 다른 테스트 기관 또는 기업을 지칭하며, KOLAS 인증기관을 통해 발급 받으셔야 합니다.

* 한국인정기구(KOLAS) 공식홈페이지(https://www.knab.go.kr)에서 [공인기관 검색] - "시험기관검색"

테스트 결과서는 첨부된 결과서 양식을 반드시 사용해야 하나요?

- 테스트 가이드에 첨부된 결과서는 하나의 참고 템플릿입니다. 가장 중요한 것은 결과서에 포함되야 할 내용들이며, 해당 내용들이 충실하게 포함되어 있다면 결과서 양식은 조금 변경되거나, 테스트 업체의 양식을 사용해도 무방합니다.

IV. 상담 사례

사업계획서상의 목표와 AI모델의 평가지표가 다릅니다.

- 사업계획서에 계획된 'AI모델 성능지표'에 준하여 테스트를 진행해야 합니다. 사업계획서에 성능 지표가 작성되어 있지 않는 경우, AI테스트 수행 전에 '협약변경 절차'를 통해 사업계획서에 평가지표를 세우고 테스트를 진행합니다.
- (사업계획서 변경은 '협약변경' 승인사항 이므로. 과제담당자에게 필히 문의바랍니다.)

테스트를 진행할 때 평가용 데이터는 누가 준비해야 하는지요

- 학습에 활용되지 않은 평가용 데이터는 의뢰기업(공급기업)에서 준비해야 합니다

테스트 결과서는 첨부된 결과서 양식을 반드시 사용해야 하나요?

- 테스트 가이드에 첨부된 결과서는 하나의 참고 템플릿입니다. 가장 중요한 것은 결과서에 포함되야 할 내용들이며, 해당 내용들이 충실하게 포함되어 있다면 결과서 양식은 조금 변경되거나, 테스트 업체의 양식을 사용해도 무방합니다.

IV. 상담 사례

여러 개 모델이 있을 때 각각을 다 테스트해야 하는지?

- **하나의 과제에 여러 AI모델을 공급하는 경우, 모델별로 테스트를 진행해야 합니다.**

꼭 테스트 결과서를 제출해야 하는지?

- **AI바우처 사업 참여 과제는 테스트 결과서를 반드시 제출해야하는 필수 제출 서류입니다.**

2023 AI바우처 사업

감사합니다.